혐오체인 :
한국어 유해표현 분석 웹 페이지

한국어 유해표현 분류 모델 개발 및 웹 기반 검증

2101018 조규상
2001584 서재철
2201331 윤건호

주제와 실행 범위

초기 제안: 임베딩 Top-K 유사 사례 검색 → 현재: 한국어 6종 통합·분류·웹 검증

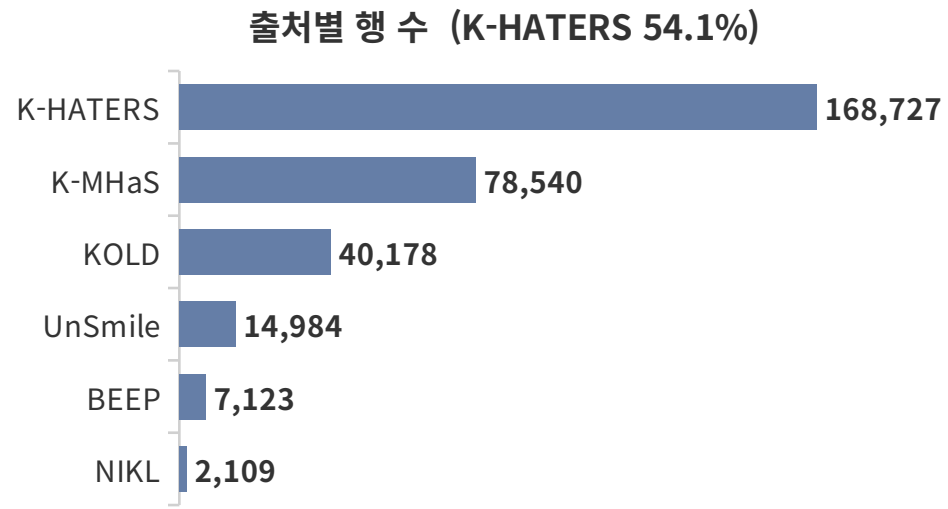
범위 결정 이유	확인한 차이
언어 구조	한국어와 영어의 어순과 정보 위치 차이
데이터 구성	언어별 데이터 양의 불균형
라벨 체계	한국어 세부 유형과 영어 toxic 라벨의 차이

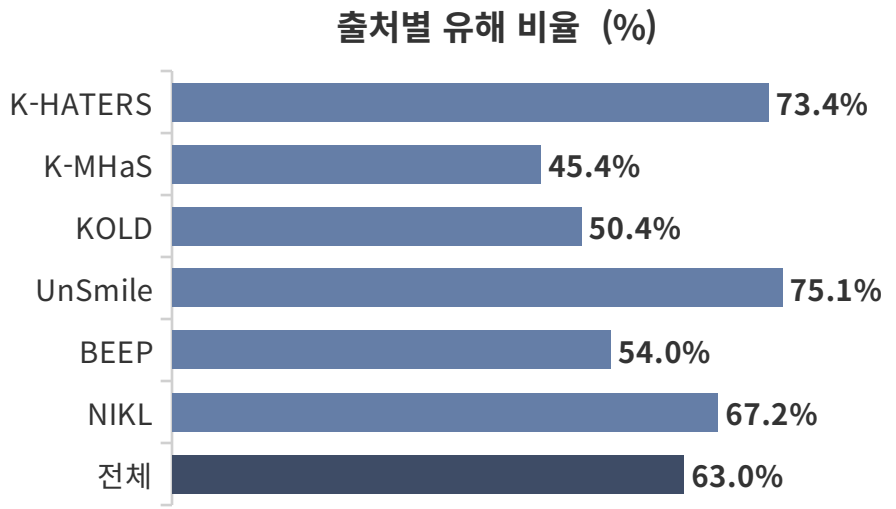
NIKL · UnSmile · KOLD · K-MHaS · K-HATERS · BEEP 라벨

중간 범위: 통합 데이터·분류기·웹 연결 / 임베딩 검색: 후속 작업

데이터셋 EDA

한국어 6종 · 정제 후 311,661행 · 필수값(문장·라벨·출처) 결측 0 · 문장 길이 중앙값 35자





K-HATERS가 54.1% · 전체 유해 63.0% · 출처·라벨 모두 불균형

선택 주석 미제공률: 문맥 84.1% · 대상 43.6% · 표현 42.6% (삭제하지 않고 보존)

전처리 파이프라인과 빅데이터 적용 위치

행 수는 각 단계 적용 후 · 원문은 보존하고 공백 정리는 중복 판별용

1 수집·파싱 — Python
6종 원천을 공통 스키마로 변환
316,574행

→

2 필수값 검사 — Python
빈 문장·라벨 누락 제외
316,571행 (−3)

→

3 정제 — Python + Spark
공백 정규화·충돌 제외·중복 병합
311,661행 (−4,910)

4 그룹 분할 — Python
연결 그룹 단위 80/10/10
249,732 / 30,580 / 31,349

→

5 저장·집계 — Hadoop
HDFS 저장 + MapReduce 집계
27개 키·해시 일치

→

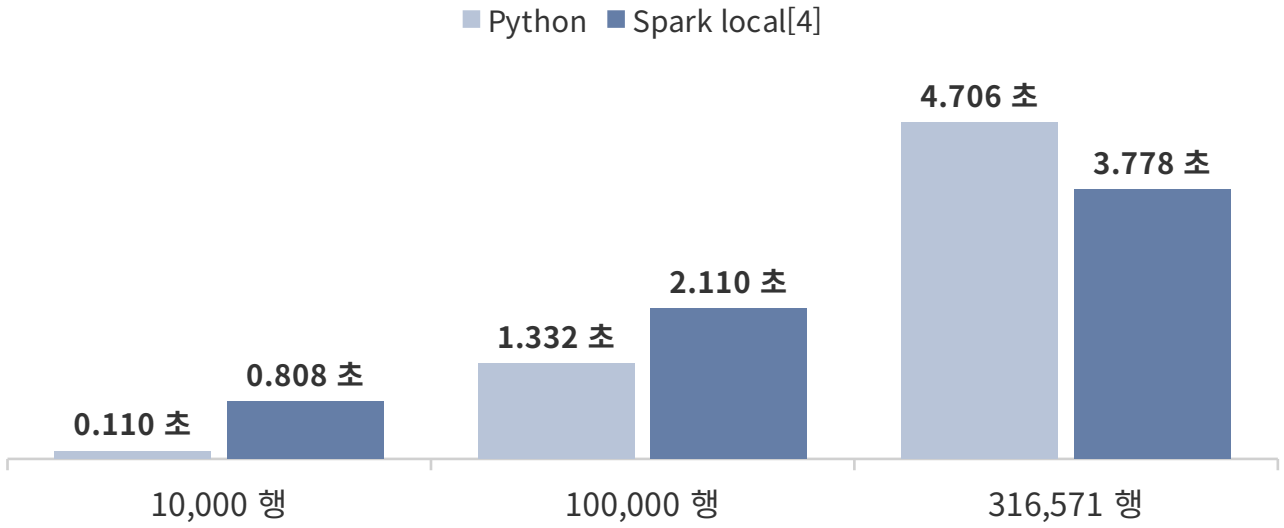
6 학습 — scikit-learn
문자 TF-IDF + LogisticRegression
모델 2종 (7장)

빅데이터 처리: 3단계 정제 = Spark, 5단계 저장·집계 = Hadoop

두 구간 모두 Python 결과와 해시·집계 일치로 검증 · 단일 서버 실행, 다중 서버 확장은 후속

같은 전처리 구간의 Python·Spark 비교

공백 정규화·충돌 제외·중복 처리 · 단일 서버 Python과 Spark local, 각 3회 중앙값



출력 키 해시

3/3 일치

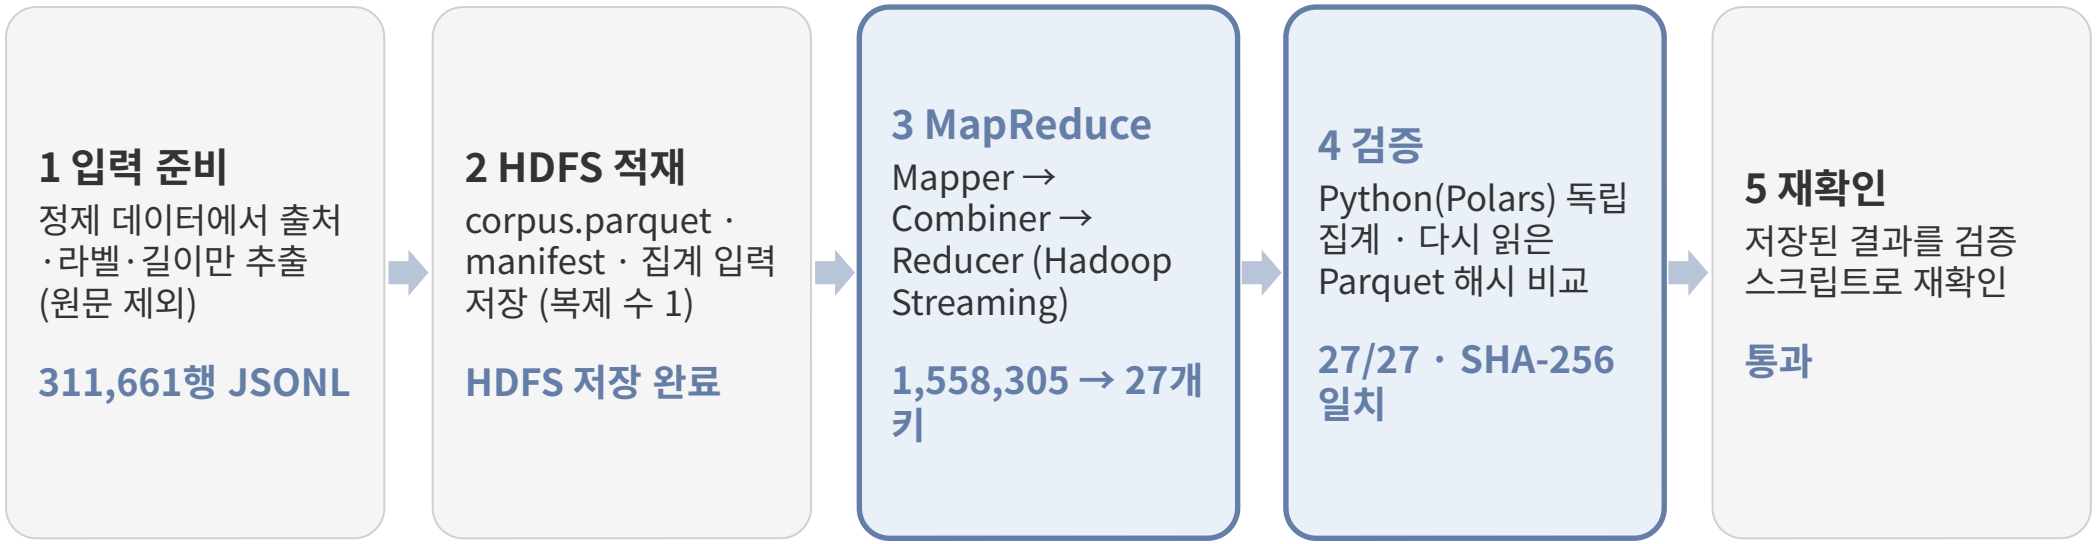
세 규모 모두 Python과 같은 결과
31.7만 행에서만 Spark가 더 짧음

Parquet 읽기·결과 수집 포함 / Spark 시작 3.302초 별도

전체 수집·분할이나 다중 서버 확장성의 비교가 아님

Hadoop 기반 저장·집계 검증

Hadoop 3.4.2 · 단일 서버 HDFS + MapReduce LocalJobRunner · YARN 미사용



정제 결과를 별도 저장·집계 경로로 교차검증 → 27개 키·Parquet 해시 일치

단일 서버 실증 · 전체 전처리 재구현이나 다중 서버 성능 실험이 아님

모델 구성과 입력·출력

전처리한 6종 데이터 → 모델 A 학습 · 웹은 한 입력에 두 모델 결과를 함께 표시

구분	모델 A · 6종 이진 분류	모델 B · K-HATERS Ratings
입력	한국어 문장 str · 1–1000자 · 한글 포함	같은 입력 (웹에서 동시 추론)
학습 데이터	6종 통합 train 249,732행	원본 Ratings train 172,097행
정답	정상 / 유해 (출처 라벨을 이진 변환)	Hate·공격성·욕설 각 0·1·2 등급
특징	문자 2–5gram TF-IDF 200,000개	문자 2–5gram TF-IDF 100,000개
분류기	LogisticRegression 1개 (balanced)	LogisticRegression 3개 + 온도 보정
출력	판정 정상·유해·보류 + 점수 0–100	Hate·공격성·욕설 점수 0–100
판정·근거	기준 43 이상 유해 · 기여 특징·후보 구간	50 × (P(1) + 2·P(2)) · 판정 기준 없음

보류: 학습한 문자 특징이 하나도 없으면 점수를 숨기고 판단 보류

모델 B는 7번째 출처가 아닌 별도 데이터·별도 모델 · 점수는 정답 확률·피해 심각도가 아님

기존 이진 test 결과

기존 내부 test 31,349건 · 문자 2–5gram TF-IDF + LogisticRegression

Macro-F1

0.7784

정상·유해 두 클래스 F1의 평균

유해 재현율

83.52%

실제 유해 중 유해로 찾은 비율

정상 오탐률

27.82%

실제 정상 중 유해로 판정한 비율

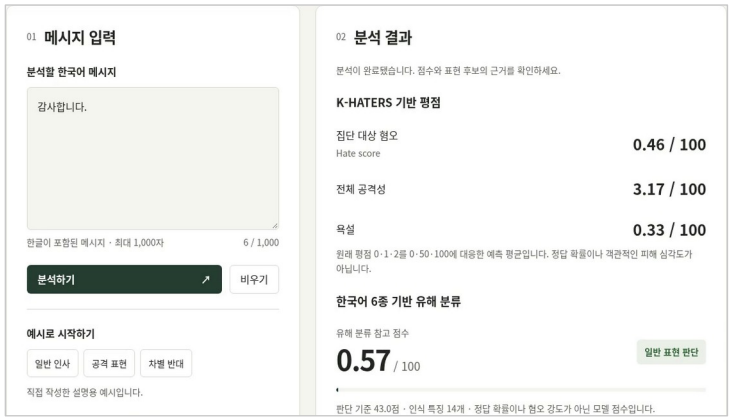
유해 문장을 찾는 성능과 정상 문장의 오탐을 함께 확인

Macro-F1은 정확도가 아님 · 서비스 성능 보장이나 독립 외부 평가가 아님

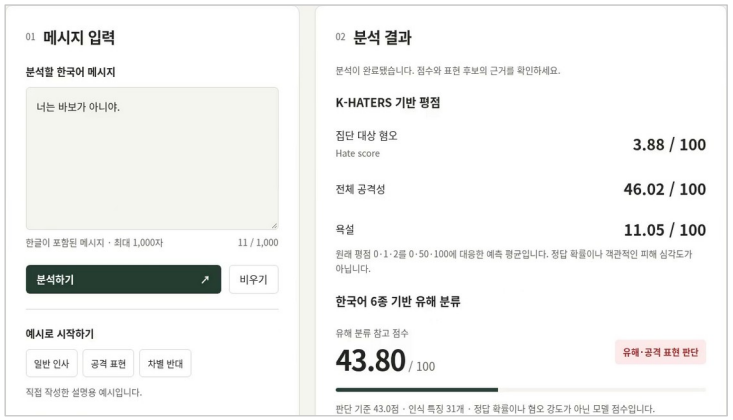
웹 실행과 부정문 오류

저장 모델을 API로 호출해 결과와 특징 표시

일반 문장 · 0.57 → 정상



부정문 · 43.80 ≥ 43 → 유해 (오탐)



QR로 직접 접속

qrfy.io/KeSupHr2bB

웹 구성: 상단 Ratings / 하단 이진 특징·삭제 전후 반응

시연 주소: playback-sight-profiles-defeat.trycloudflare.com

후속 실험 계획

현재 모델(문자 TF-IDF + LR)을 기준선으로 고정 · 후보 선택은 validation, test는 최종 1회 보고

실험	목적	비교	평가 지표
E1 오류 유형 평가셋	부정·인용·동음이의어 오탐 측정	유형별 기준 작성 후 구축	유형별 오탐률
E2 짧은 입력 보류	특징 1–2개로 판정하는 문제 완화	인식 특징 수 기준값	정상 오탐률·보류율
E3 문맥 모델	부정·문맥 반영 여부 확인	사전학습 모델 vs 기준선	Macro-F1·유형별 오탐
E4 출처×길이 분석	출처별 라벨 정의 차이 확인	출처·길이 구간별 오류	재현율·오탐률

예: '시래기' 74.33 유해 — 학습 데이터 9건 모두 '쓰레기' 변형 욕설

E3 모델 종류·E2 기준값은 실험 전에 확정 · 계획이며 개선 결과를 보장하지 않음

소논문 방향과 작성 일정

주제(안): 다출처 한국어 유해표현 통합 데이터와 문자 기반 분류기의 오류 분석

11/5–11/11	11/12–11/18	11/19–11/25	11/26–11/30	12월 초
관련 연구 정리 · 오류 유형 평가셋 구축 (E1)	보류 규칙·문맥 모델 비교 실험 (E2·E3)	출처×길이 분석 (E4) · 소논문 초안 작성	팀 검토·수정 · 최종 발표 자료 준비	최종 발표
→ 관련 연구 요약 · 평가셋	**→ 실험 결과표**	**→ 소논문 초안**	**→ 소논문 최종본 · 발표 자료**	**→ 시연 · 발표**

연구 질문: 문자 기반 분류기는 어떤 출처·문장 유형에서 틀리는가

11월 말까지 소논문 마무리 → 12월 초 최종 발표 · 최종 제목·범위는 팀 검토 후 확정

프로젝트 R&R과 예상 산출물

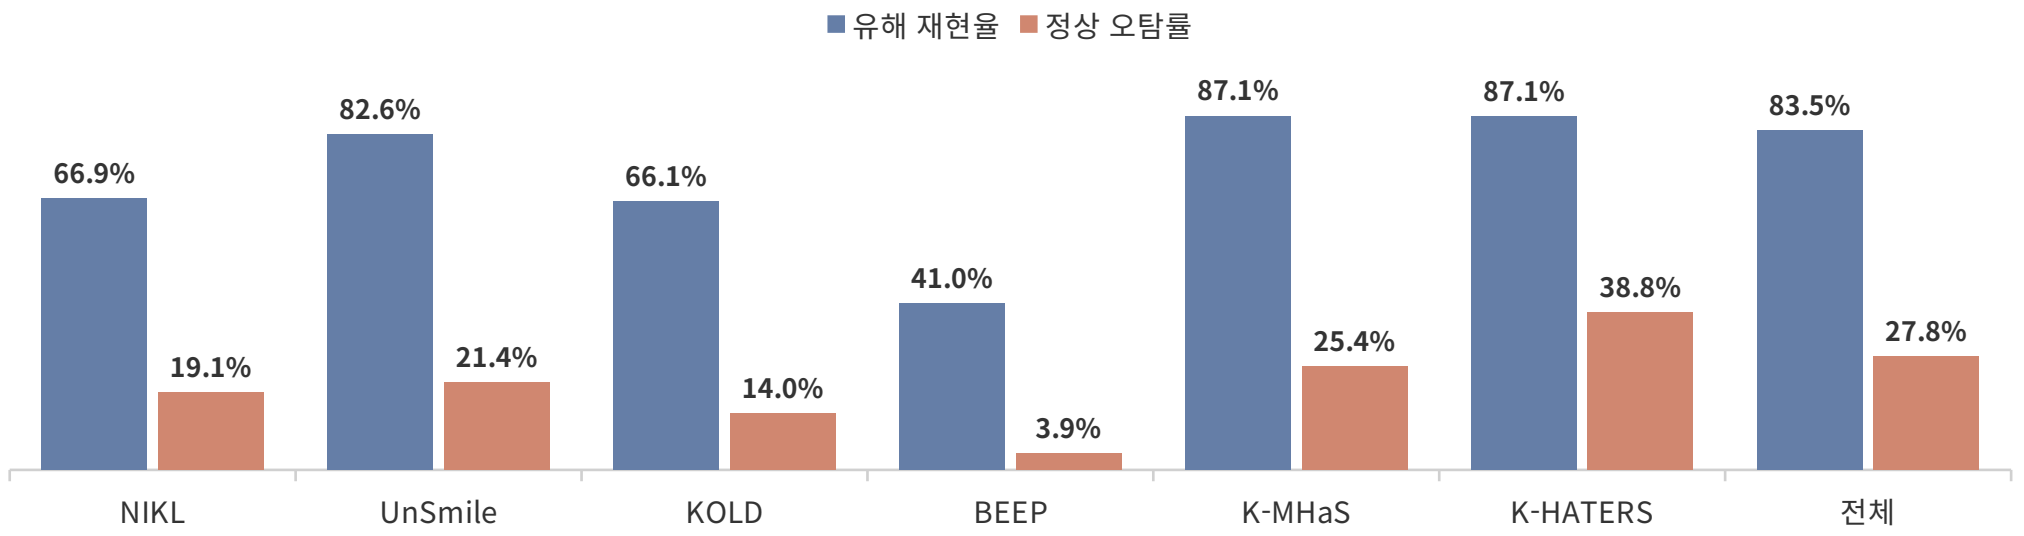
3인 역할 분담 · 결과 해석·전체 검토·리허설은 공동

이름	역할	주요 담당	예상 산출물
조규상	모델·실험	전처리 공동 주도·모델 학습·비교·고정	학습 모델·성능표·재현 정보
서재철	데이터·자료	전처리·라벨 점검·오류 유형 분류·PPT	오류 사례표·EDA·발표 자료
윤건호	웹·서비스	웹 통합·시연 흐름·점수 설명·연결 검증	웹 시연·백업 영상
공통	—	결과 해석 검토·리허설·소논문 집필	소논문·최종 발표

예상 산출물: 정제 데이터 · 모델 2종 · 웹 시연 · 소논문 · 최종 발표

부록 · 이진 모델의 출처별 test 성능

선택 모델(문자 2–5gram, 특징 200,000, 기준 0.43) · 기존 내부 test

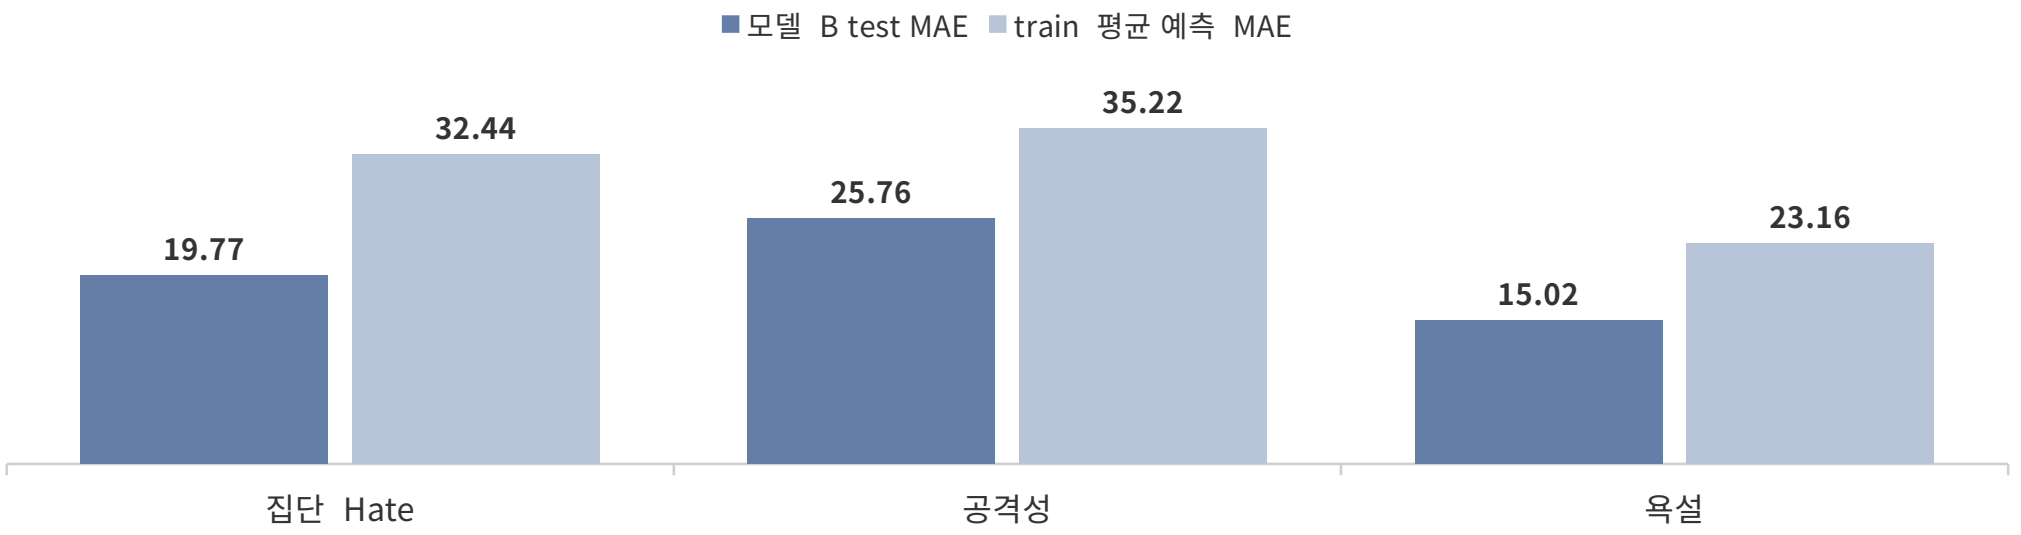


BEEP은 재현율이 낮고 K-HATERS는 오탐률이 높음 · A4 진단과 같은 방향

이미 확인한 test의 후속 집계 · 출처마다 라벨 정의가 달라 출처 간 우열 비교가 아님

부록 · K-HATERS Ratings 3종 성능

제한 정규화 v2 · 공식 validation/test 각 9,997건 · 점수 = 50 × (P(1) + 2·P(2))



세 점수 모두 train 평균 예측보다 MAE가 낮음 (Hate 32.44 → 19.77)

test는 이미 확인한 후속 비교 · 점수는 정답 확률이나 피해 심각도가 아님

부록 · 개선 후보와 선택

모델별 validation에서 선택 기준을 함께 비교

실험	주요 결과	선택
Ratings 제한 정규화	Hate MAE 19.9905 → 19.8762	채택
Ratings 불균형 보정	등급 0 오탐 5.40% → 21.78%	미채택
이진 문자 2–8gram	Macro-F1 0.784121 → 0.783041	기존 유지

한 지표의 상승보다 오차·오탐·재현율 조건을 함께 확인

이미 본 test의 후속 비교에서 욕설 MAE는 악화 · 독립 일반화 검증 아님

부록 · 출처·길이별 오류 진단

기존 validation의 고정 모델 재진단



validation 30,580건 중 API 허용·특징 인식 30,509건 기준

재학습·임계값 변경 없음 · 출처·길이 차이의 원인은 후속 확인

부록 · 정규화·형태소 재학습 비교

출처·라벨 상한 표본 (학습 11,559 / 검증 2,205 / 평가 2,211) · 특징 60,000개 · Kiwi 0.24.0

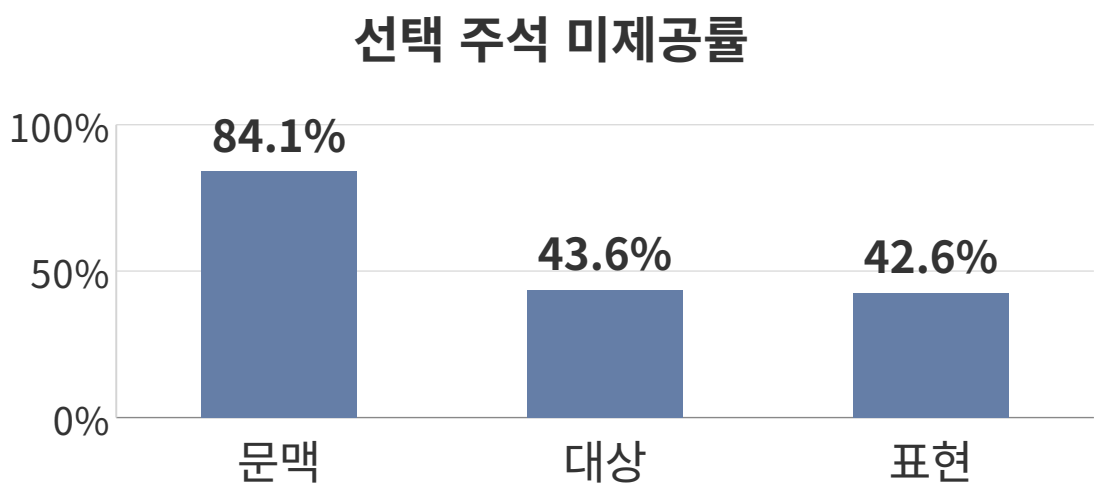
재학습 모델	검증 F1	평가 F1	유해 재현율	일반 오탐률
원문 문자 (기준)	0.7349	0.7360	76.31%	29.16%
+ 정규화 문자	0.7392	0.7273	70.12%	24.46%
+ 형태소	0.7473	0.7462	73.43%	24.08%
+ 정규화 문자 + 형태소	0.7416	0.7345	74.91%	28.03%

형태소: F1 +0.0102지만 재현율 하락·문맥 오류 그대로 → 형태소 제외 결정

소규모 표본·단일 seed · 현재 운영 모델의 F1과 직접 비교하지 않음

부록 · 선택 주석 미제공률과 필수화 비교

EDA · 정제 후 311,661행 기준 · Hadoop과 무관한 Python 분석



보조 검증: 선택 주석 필수화

7,149행

전체의 2.3%만 남음

가상 정책 비교 · 실제 삭제 아님

모두 필수로 하면 304,512행(97.7%) 제외 → 미채택, 주석 보존

빈 주석은 원천 미제공과 비해당이 섞임 · 결측 오류로 보지 않음 · 실제 삭제 없음

부록 · 시연 화면 추가 사례

공개 웹 녹화 장면 · 결과 패널만 잘라 표시

욕설 · 95.57 유해 / 욕설 58.43



후보 삭제 · 98.78 → 87.02 (−11.76)



특징 없음 · 판단 보류

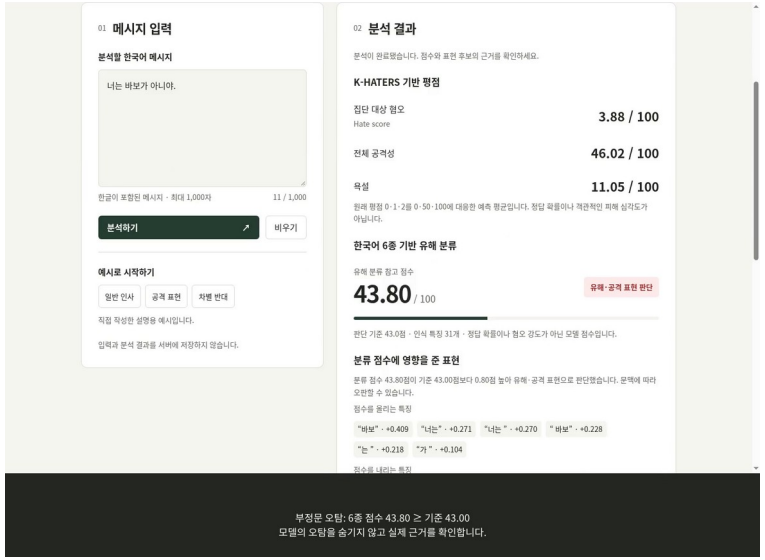


후보 삭제 비교와 보류는 6종 분류기의 설명 · K-HATERS 평점의 근거가 아님

표현 후보는 사람이 확정한 유해 구간이 아님 · 구간 삭제 시 문장 의미도 달라짐

부록 · 시연 영상 (46초)

공개 웹 실제 입력 5개 녹화 · 자막 해설 포함 · 무음



본문 5분에 포함하지 않음 · 질의응답 또는 시간 여유가 있을 때 재생

공개 주소 장애 시 이 영상으로 대체 · 클릭하면 재생