혐오체인 :
한국어 유해표현 분석 웹 페이지

한국어 유해표현 분류 모델 개발 및 웹 기반 검증

2101018 조규상
2001584 서재철
2201331 윤건호

문제 정의: 한국어 문장의 유해 여부 분류

과제 = 정답이 있는 지도학습 · 주 과제는 **분류(모델 A)**, 보조 과제는 **점수 예측(모델 B)**

입력
한국어 문장 1개
1–1000자 · 한글 포함

→

숫자 속성 x
문자 2–5gram TF-IDF
문장 → 숫자 벡터 (6장)

→

모델 A · 분류
정상 / 유해
6종 통합 데이터로 학습

모델 B · 점수 예측
Hate·공격성·욕설 0–100
K-HATERS 평점으로 학습

구분	과제 유형	정답 y	평가 지표
모델 A	**이진 분류**	정상 0 / 유해 1 (6종 라벨 변환, 311,661행)	Macro-F1 · 유해 재현율 · 정상 오탐률
모델 B	3등급 분류 → 점수 예측	평점 0·1·2 (K-HATERS 172,097행)	MAE(0–100점) · 등급 Macro-F1

EDA로 현황 파악 → 라벨을 정답(0/1)으로, 문장을 숫자 속성(벡터)으로 변환 → 학습·평가

초기 제안(임베딩 Top-K 유사 사례 검색)은 후속 작업 · 언어 구조·데이터 양·라벨 체계 차이로 한국어 6종에 집중

6종 라벨 구조와 정답(0/1) 변환

출처마다 라벨 체계가 달라 **정상 = 0 / 유해 = 1**로 통일 · 같은 데이터 안에서 모순된 라벨은 제외

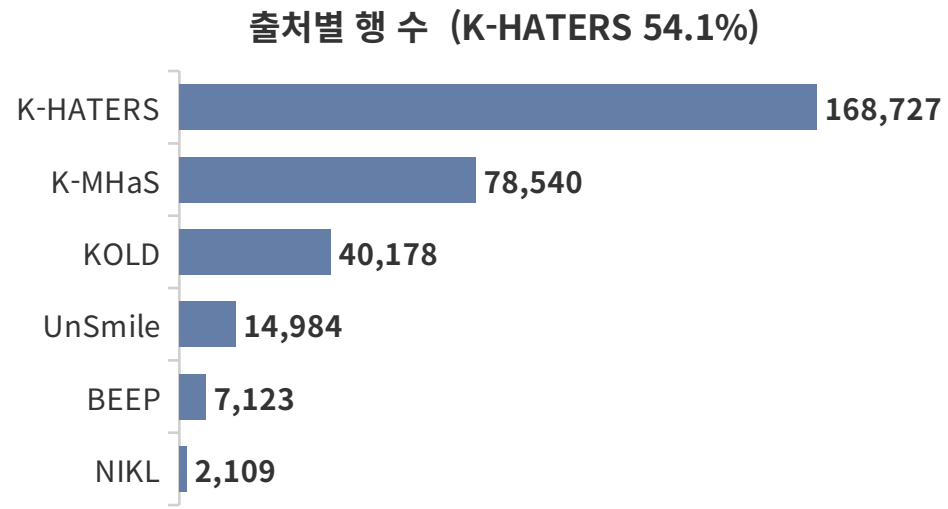
출처	원래 라벨 체계	정상 = 0	유해 = 1	제외
NIKL	대화 맥락 + 대상 발화의 적절/부적절	적절	부적절	—
UnSmile	혐오 유형 9개·개인 지칭 다중 표시 + '깨끗함'	깨끗함만 표시	혐오 유형 1개 이상	**깨끗함+혐오 동시**
KOLD	뉴스 댓글 공격 여부 + 대상·표현 위치	공격 아님	공격적	—
K-MHaS	혐오 유형 번호 다중(0–7) + 혐오 아님(8)	8만	0–7만	**8과 0–7 혼재**
K-HATERS	4단계: 정상·공격적·약한 혐오·강한 혐오	정상	공격적·약한·강한	그 외 라벨·빈 문장
BEEP	연예 댓글 3단계: 없음·공격적·혐오	없음	공격적·혐오	—

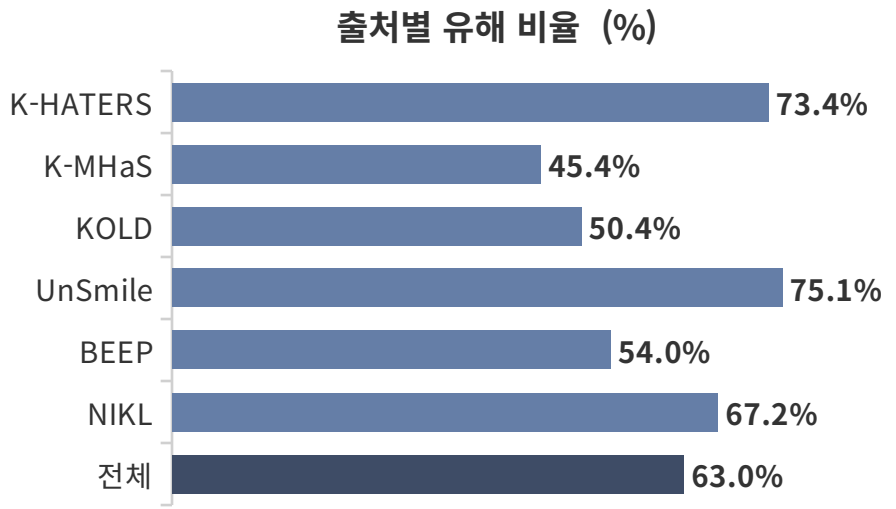
정답 y: 정상 115,328행 (37.0%) · 유해 196,333행 (63.0%) — 합계 311,661행

세부 유형·대상·표현 위치는 이진 학습에 쓰지 않음 · 출처별 '유해' 기준 차이는 E4에서 분석

데이터셋 EDA

한국어 6종 · 정제 후 **311,661행** · 필수값(문장·라벨·출처) **결측 0** · 문장 길이 **중앙값 35자**





K-HATERS 54.1% · 유해 63.0% → 불균형 → Macro-F1 평가 · 클래스 가중치 학습

선택 주석 미제공률: 문맥 **84.1%** · 대상 43.6% · 표현 42.6% (**삭제하지 않고 보존**)

전처리 파이프라인과 빅데이터 적용 위치

정답(0/1) 데이터와 학습용 분할을 만드는 단계 · 행 수는 각 단계 적용 후 · 원문은 보존

1 수집·파싱 — Python
6종 원천을 **공통 스키마**로 변환
316,574행

→

2 필수값 검사 — Python
빈 문장·라벨 누락 제외
316,571행 (−3)

→

3 정제 — Python + Spark
공백 정규화·충돌 제외·중복 병합
311,661행 (−4,910)

4 그룹 분할 — Python
연결 그룹 단위 80/10/10
249,732 / 30,580 / 31,349

→

5 저장·집계 — Hadoop
HDFS 저장 + MapReduce 집계
27개 키·해시 일치

→

6 학습 — scikit-learn
문자 TF-IDF + LogisticRegression
모델 2종 (7장)

빅데이터 처리: 3단계 정제 = Spark, 5단계 저장·집계 = Hadoop

두 구간 모두 Python 결과와 **해시·집계 일치**로 검증 · **단일 서버 실행**, 다중 서버 확장은 후속

문장을 숫자 속성으로: 문자 n-gram TF-IDF

예: '너는 정말 멍청한 바보야.' → 2–5글자 조각 46개 → 사전(20만)에 있는 **28개만 0이 아닌 값**

① 조각 빈도 tf(t, d) = 문장 d에서 조각 t의 횟수

② **TF-IDF**

$$x_t = (1 + \ln tf) \times idf(t)$$

$$idf(t) = \ln((1 + N) / (1 + df(t))) + 1$$

N = train 249,732문장, df = 조각이 나온 문장 수

③ 길이 정규화 $x \leftarrow x / \|x\|_2$

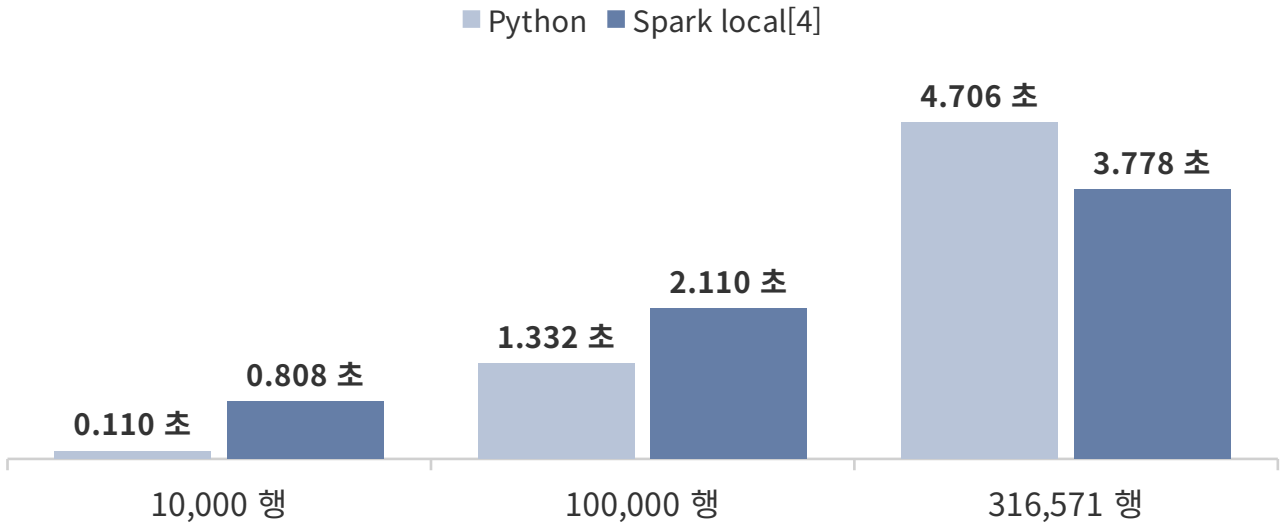
조각 t	x_t (TF-IDF)	w_t (모델 A)	x_t · w_t
멍청	0.190	4.273	**0.812**
␣멍	0.187	2.698	**0.505**
바보	0.195	2.510	**0.489**
멍청한	0.208	1.832	**0.381**
청한	0.206	1.764	**0.362**
… 나머지 23개			…
합계 Σ x·w			**5.733**

정답 y는 0/1, 속성 x는 200,000차원 숫자 벡터 → 모델 A·B의 공통 입력 형식

출처·그룹 ID·원래 세부 라벨은 속성으로 쓰지 않음 · 조각 사전과 idf는 train에서만 계산

같은 전처리 구간의 Python·Spark 비교

공백 정규화·충돌 제외·중복 처리 · **단일 서버 Python과 Spark local**, 각 **3회 중앙값**



출력 키 해시

3/3 일치

세 규모 모두 Python과 같은 결과
31.7만 행에서만 Spark가 더 짧음

Parquet 읽기·결과 수집 포함 / Spark 시작 3.302초 별도

전체 수집·분할이나 **다중 서버 확장성**의 비교가 아님

Hadoop 기반 저장·집계 검증

Hadoop 3.4.2 · **단일 서버 HDFS + MapReduce** LocalJobRunner · **YARN 미사용**

1 입력 준비
정제 데이터에서 **출처·라벨·길이만** 추출 (**원문 제외**)

311,661행 JSONL

2 HDFS 적재
corpus.parquet · manifest · 집계 입력 저장 (복제 수 1)

HDFS 저장 완료

3 MapReduce
Mapper → Combiner → Reducer (Hadoop Streaming)

1,558,305 → 27개 키

4 검증
Python(Polars) 독립 집계 · 다시 읽은 Parquet 해시 비교

27/27 · SHA-256 일치

5 재확인
저장된 결과를 **검증 스크립트**로 재확인

통과

정제 결과를 별도 저장·집계 경로로 교차검증 → 27개 키·Parquet 해시 일치

단일 서버 실증 · 전체 전처리 재구현이나 다중 서버 성능 실험이 아님

HDFS–Spark 연동 파이프라인

중간발표: 두 도구를 따로 실행 → 보완: **Spark가 HDFS에서 읽고 HDFS에 쓰도록** 연결

Bronze · HDFS
원천 316,571행
Parquet 적재
검증: HDFS 해시 = 로컬 해시

→

Silver · Spark
HDFS에서 읽어
정규화·충돌 제외·중복 병합
검증: 출력 키 해시 = Python

→

Gold · Spark SQL
Silver를 읽어
출처·라벨·길이 27개 키
검증: Spark 집계 = Python

→

Gold · MapReduce
HDFS Silver 입력
Map → Combine → Reduce
검증: MapReduce = Spark = Python

hdfs://…/bigdb/pipeline/ bronze/raw_input.parquet → silver/corpus/ · silver/mr_input/ → gold/spark_aggregates/ · gold/mapreduce_aggregates/
실행: bigdata/run_pipeline.sh (HDFS 기동 → 적재 → Spark → MapReduce → 검증)

Bronze → Silver(학습 데이터용 정제) → Gold(집계) 모두 HDFS · 단계마다 Python과 대조

구성 완료 · 전체 실행 검증은 재실행 후 반영 · 단일 서버 · 다중 서버 확장성은 미측정

모델 구성과 입력·출력

전처리한 6종 데이터 → **모델 A 학습** · 웹은 한 입력에 **두 모델 결과를 함께** 표시

구분	모델 A · 6종 이진 분류	모델 B · K-HATERS Ratings
입력	한국어 문장 str · **1–1000자** · **한글 포함**	같은 입력 (웹에서 동시 추론)
학습 데이터	6종 통합 train **249,732행**	원본 Ratings train **172,097행**
정답	**정상 / 유해** (출처 라벨을 이진 변환)	Hate·공격성·욕설 각 **0·1·2 등급**
특징	문자 2–5gram TF-IDF **200,000개**	문자 2–5gram TF-IDF **100,000개**
분류기	**LogisticRegression 1개** (balanced)	**LogisticRegression 3개 + 온도 보정**
출력	판정 **정상·유해·보류** + 점수 0–100	Hate·공격성·욕설 점수 0–100
판정·근거	**기준 43 이상 유해** · 기여 특징·후보 구간	**50 × (P(1) + 2·P(2))** · **판정 기준 없음**

보류: 학습한 문자 특징이 하나도 없으면 점수를 숨기고 판단 보류

모델 B는 7번째 출처가 아닌 **별도 데이터·별도 모델** · 점수는 **정답 확률·피해 심각도가 아님**

모델 A 수식: 이진 로지스틱 회귀

6종 통합 train **249,732행** · 속성 x = 문자 2–5gram TF-IDF 200,000차원 · 정답 y ∈ {0, 1}

① 확률

$z = w^{T}x + b$

$P(\text{유해} \mid x) = \sigma(z) = 1 / (1 + e^{-z})$

w: 조각별 가중치 20만 개

b: 절편

② 학습 (손실 최소화)

$\min \tfrac{1}{2} \| w \|^{2} + C \cdot \Sigma_i \, c_y_i \cdot \log(1 + e^{(-\tilde{y}_i z_i)})$

$\tilde{y} = \pm 1$, C = 1 (L2 규제)

클래스 가중치 $c_y = N / (2 \cdot N_y)$

→ 유해 63% 불균형 보정

③ 판정

점수 = 100 × P

P ≥ 0.43 → 유해

P < 0.43 → 정상

인식 조각 0개 → 판단 보류

예: '너는 정말 멍청한 바보야.' z = 5.733 − 1.341 = 4.392 → P = 0.988 → 98.8점 ≥ 43 → 유해

기준 0.43과 설정(2–5gram·20만)은 validation Macro-F1로 선택 · test는 최종 보고에만 사용

모델 B 수식: 평점 3등급 분류 → 점수

K-HATERS Ratings train **172,097행** · x = 문자 2–5gram TF-IDF 10만 차원 · 점수 3개 각각 학습

① 정답 (각 0·1·2)

Hate = max(성별·연령·장애·직업·인종·종교·정치)

공격성 = max(평점 13개 전체)

욕설 = 욕설 평점

② 확률 (다항 로지스틱 회귀)

$z_k = w_k^T x + b_k,\ k \in \{0, 1, 2\}$

$P(k \mid x) = e^{(z_k/T)} / \Sigma_j e^{(z_j/T)}$

lbfgs · T = 1.0

③ 점수

$S = 50 \cdot P(1) + 100 \cdot P(2)$

$= 50 \times (P(1) + 2 \cdot P(2))$

0점(모두 0등급) ~ 100점(모두 2등급)

판정 기준 없이 세 점수를 함께 표시 · 점수는 정답 확률이나 피해 심각도가 아님

모델 A와 별도 데이터·모델 · 온도 T는 validation NLL로 선택(1.0) · 정규화 v2는 validation MAE로 채택

모델 A (6종 이진 분류) test 결과

311,661행을 연결 그룹 단위로 나눈 **test 31,349건** (학습에 쓰지 않은 10%)

Macro-F1

0.7784

정상·유해 두 클래스 **F1의 평균**

유해 재현율

83.52%

실제 유해 중 **유해로 찾은 비율**

정상 오탐률

27.82%

실제 정상 중 **유해로 판정한 비율**

정상 오탐률 27.82% = 실제 정상 11,599건 중 3,227건을 유해로 판정 (계산은 14장)

Macro-F1은 **정확도가 아님** · 서비스 성능 보장이나 **독립 외부 평가가 아님**

모델 A 혼동행렬과 지표 계산

test 31,349건 (정상 11,599 · 유해 19,750) · 판정 기준 43점

	예측 정상	예측 유해	합계
실제 정상	8,372 (TN)	**3,227 (FP)**	11,599
실제 유해	3,254 (FN)	**16,496 (TP)**	19,750
합계	11,626	19,723	31,349

정상 오탐률 = FP / 실제 정상 = 3,227 / 11,599 = **27.82%**

유해 재현율 = TP / 실제 유해 = 16,496 / 19,750 = **83.52%**

유해 정밀도 = TP / 예측 유해 = 16,496 / 19,723 = 83.64%

F1 = 2 × 정밀도 × 재현율 / (정밀도 + 재현율)

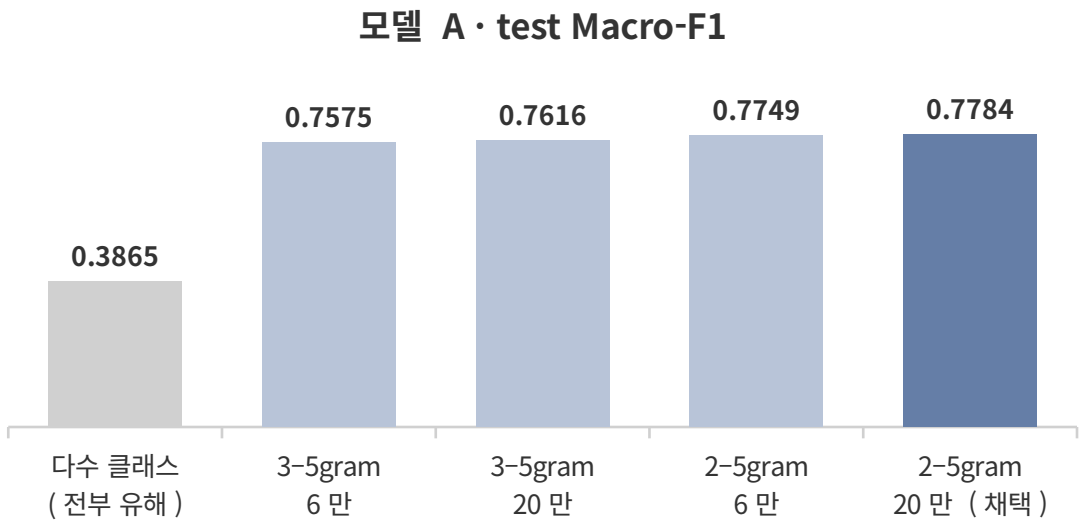
Macro-F1 = (F1 정상 0.7209 + F1 유해 0.8358) / 2 = **0.7784**

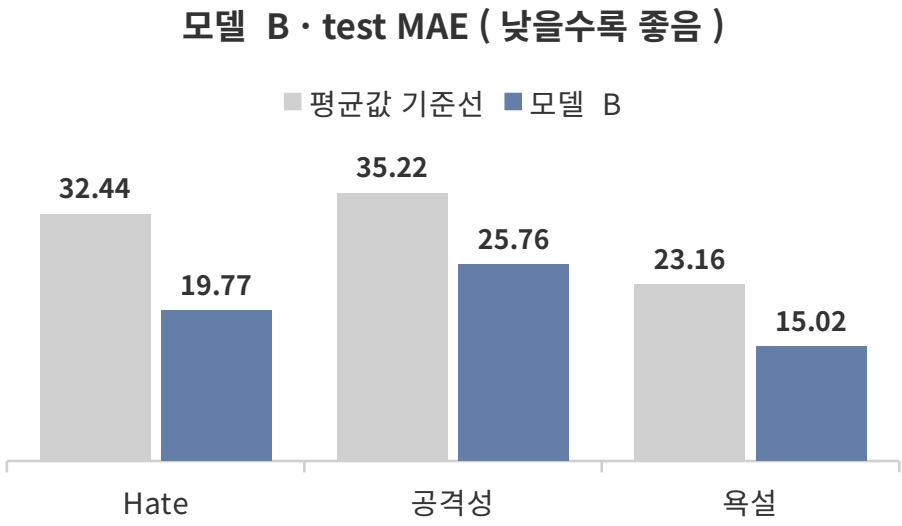
정상 문장 4개 중 1개 이상을 유해로 판정 → 오탐 줄이기가 핵심 과제 (18장)

정확도 79.33%는 유해가 63%인 불균형에서 과대평가될 수 있어 Macro-F1·재현율·오탐률을 함께 봄

얼마나 잘 만들었나: 기준선과 비교

같은 test에서 단순 기준선·다른 설정과 비교 · 설정 선택은 validation 기준



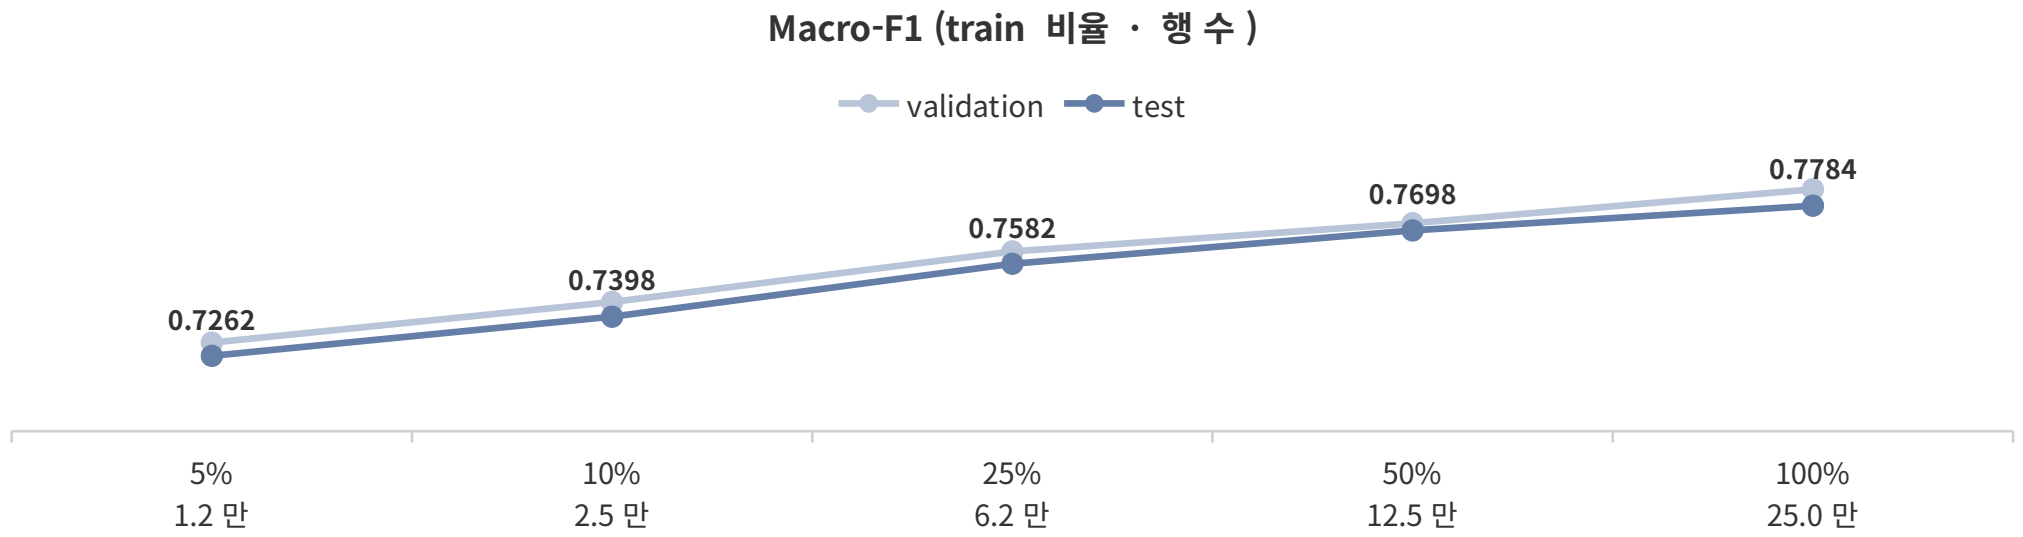


모델 A: 다수 클래스 기준선 0.3865 → 0.7784 · 모델 B: 평균값 기준선보다 MAE 27–39% 낮음

다수 클래스 = 모든 문장을 유해로 판정 · 평균값 = train 평균 점수를 항상 출력 · 통계적 유의성 검정은 하지 않음

데이터 규모 실험: 학습 데이터가 늘면 성능은?

train만 5–100%로 줄여 재학습 · validation·test·모델 설정(2–5gram, 20만, 가중치)은 고정



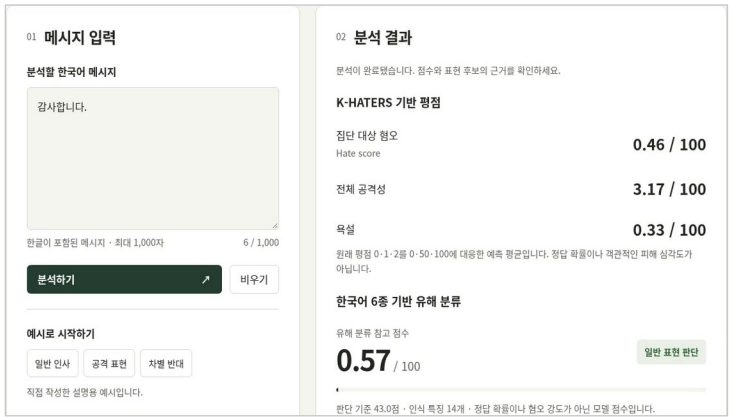
train 12,487행 → 249,732행: test Macro-F1 0.7262 → 0.7784, 데이터가 늘수록 계속 상승

증가 폭은 줄어드는 추세(50% → 100%: +0.0086) · 같은 6종 안의 비교이며 새 출처 추가 효과는 아님

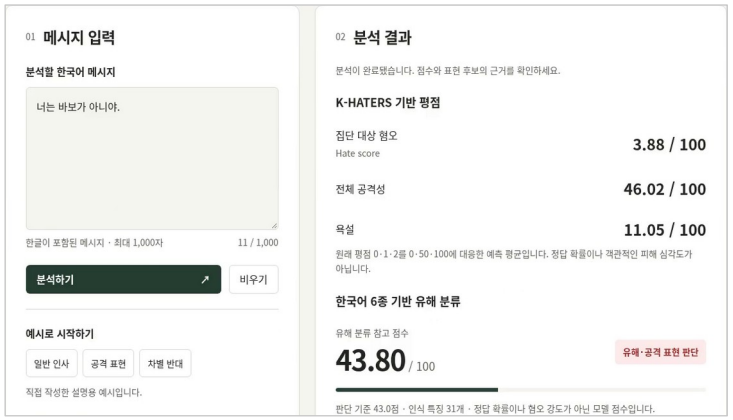
웹 실행과 부정문 오류

저장 모델을 **API로 호출**해 **결과와 특징** 표시

일반 문장 · 0.57 → 정상



부정문 · 43.80 ≥ 43 → 유해 (오탐)



QR로 직접 접속

qrfy.io/KeSupHr2bB

웹 구성: 상단 Ratings / 하단 이진 특징·삭제 전후 반응

시연 주소: playback-sight-profiles-defeat.trycloudflare.com

오탐 원인과 판단 보류 규칙

모델은 그대로, 불확실한 '유해' 판정만 **보류** · 규칙은 validation으로 선택, test 1회 평가

입력	점수	원인	규칙 적용 후
시래기	74.33	조각 1개('래기')가 점수를 결정 · 학습 데이터 9건 모두 '쓰레기' 변형	**보류**
너는 바보가 아니야.	43.80	기준 43 바로 위 · 부정문 안의 '바보'도 유해 쪽	**보류**
쓰레기 / 시발	99.76 / 95.57	점수가 높아 규칙 대상 아님	유해 유지
닥쳐	55.94	조각 1개 · 점수 80 미만	**보류 (부작용)**

R1 경계 보류: 43 ≤ 점수 < 48 → 보류　　**R2 단일 조각 보류**: 인식 조각 ≤ 2개 · 최대 조각 비중 ≥ 60% · 점수 < 80 → 보류
선택 기준: validation 보류율 5% 이하에서 자동 판정 Macro-F1 최대 (경계 폭·조각 수·비중·점수 상한 격자 탐색)

test: 보류 4.79% · 자동 판정의 정상 오탐률 27.86% → 23.64% · Macro-F1 0.7783 → 0.7920

보류 1,501건 중 844건은 실제 유해 → 사람 검토가 필요 · 부정문·동음이의어 자체는 문맥 모델(E3)로 해결해야 함

후속 실험 계획

현재 모델(문자 TF-IDF + LR)을 **기준선으로 고정** · 후보 선택은 **validation**, **test는 최종 1회** 보고

실험	목적	비교	평가 지표
E1 오류 유형 평가셋	**부정·인용·동음이의어 오탐** 측정	유형별 기준 작성 후 구축	**유형별 오탐률**
E2 짧은 입력 보류	**특징 1–2개**로 판정하는 문제 완화	인식 특징 수 기준값	**정상 오탐률·보류율**
E3 문맥 모델	**부정·문맥** 반영 여부 확인	사전학습 모델 vs 기준선	**Macro-F1·유형별 오탐**
E4 출처×길이 분석	출처별 **라벨 정의 차이** 확인	출처·길이 구간별 오류	**재현율·오탐률**

E2 1차 결과: 보류 규칙으로 자동 판정 오탐률 4.2%p 감소 (18장) → 웹 반영 검토

E3 모델 종류·E2 기준값은 실험 전에 확정 · 계획이며 개선 결과를 **보장하지 않음**

소논문 방향과 작성 일정

주제(안): **다출처 한국어 유해표현 통합 데이터**와 문자 기반 분류기의 **오류 분석**

11/5–11/11	11/12–11/18	11/19–11/25	11/26–11/30	12월 초
관련 연구 정리 · 오류 유형 평가셋 구축 **(E1)**	보류 규칙·문맥 모델 비교 실험 **(E2·E3)**	출처×길이 분석 **(E4)** · 소논문 초안 작성	팀 검토·수정 · 최종 발표 자료 준비	최종 발표
→ 관련 연구 요약 · 평가셋	**→ 실험 결과표**	**→ 소논문 초안**	**→ 소논문 최종본 · 발표 자료**	**→ 시연 · 발표**

연구 질문: 문자 기반 분류기는 어떤 출처·문장 유형에서 틀리는가

11월 말까지 소논문 마무리 → **12월 초 최종 발표** · 최종 제목·범위는 팀 검토 후 확정

프로젝트 R&R과 예상 산출물

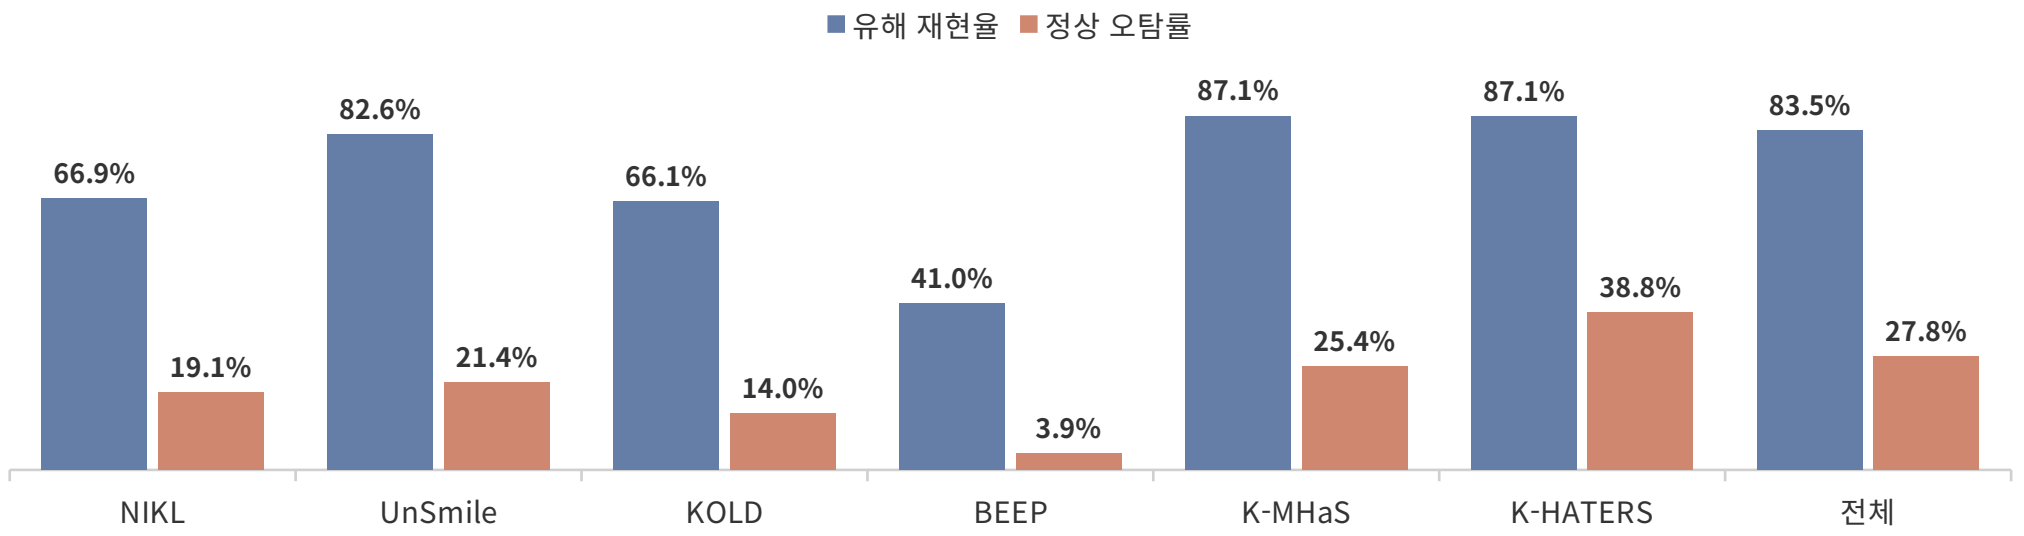
3인 역할 분담 · 결과 해석·전체 검토·리허설은 **공동**

이름	역할	주요 담당	예상 산출물
조규상	**모델·실험**	전처리 **공동** 주도·**모델 학습·비교·고정**	학습 모델·성능표·재현 정보
서재철	**데이터·자료**	전처리·라벨 점검·**오류 유형 분류**·PPT	오류 사례표·EDA·발표 자료
윤건호	**웹·서비스**	**웹 통합·시연 흐름**·점수 설명·연결 검증	웹 시연·백업 영상
공통	—	**결과 해석 검토·리허설·소논문 집필**	소논문·최종 발표

예상 산출물: 정제 데이터 · 모델 2종 · 웹 시연 · 소논문 · 최종 발표

부록 · 이진 모델의 출처별 test 성능

선택 모델(문자 2–5gram, 특징 200,000, 기준 0.43) · 기존 내부 test

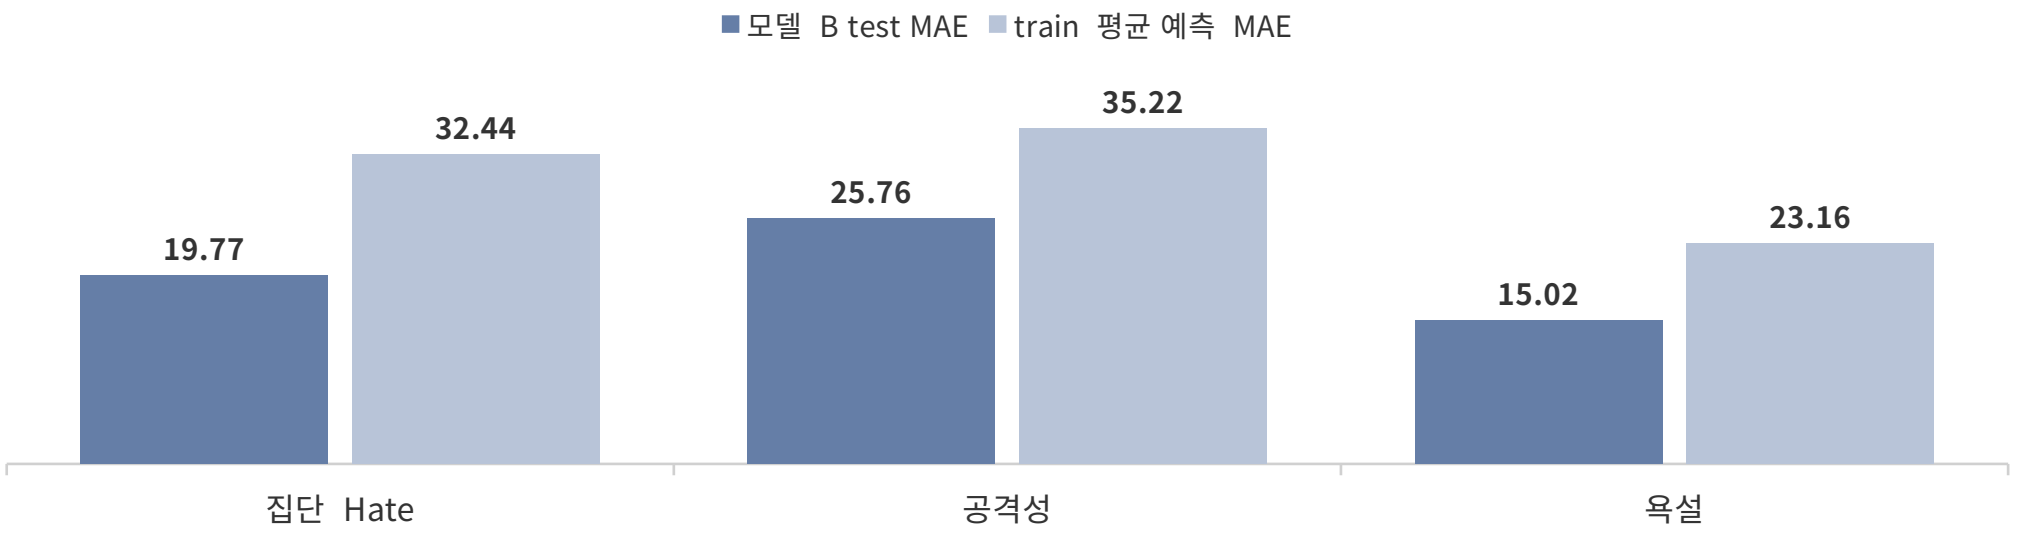


BEEP은 재현율이 낮고 K-HATERS는 오탐률이 높음 · A4 진단과 같은 방향

이미 확인한 test의 후속 집계 · 출처마다 라벨 정의가 달라 출처 간 우열 비교가 아님

부록 · K-HATERS Ratings 3종 성능

제한 정규화 v2 · 공식 validation/test 각 9,997건 · 점수 = 50 × (P(1) + 2·P(2))



세 점수 모두 train 평균 예측보다 MAE가 낮음 (Hate 32.44 → 19.77)

test는 이미 확인한 후속 비교 · 점수는 정답 확률이나 피해 심각도가 아님

부록 · 개선 후보와 선택

모델별 validation에서 선택 기준을 함께 비교

실험	주요 결과	선택
Ratings 제한 정규화	Hate MAE 19.9905 → 19.8762	채택
Ratings 불균형 보정	등급 0 오탐 5.40% → 21.78%	미채택
이진 문자 2–8gram	Macro-F1 0.784121 → 0.783041	기존 유지

한 지표의 상승보다 오차·오탐·재현율 조건을 함께 확인

이미 본 test의 후속 비교에서 욕설 MAE는 악화 · 독립 일반화 검증 아님

부록 · 출처·길이별 오류 진단

기존 validation의 고정 모델 재진단



validation 30,580건 중 API 허용·특징 인식 30,509건 기준

재학습·임계값 변경 없음 · 출처·길이 차이의 원인은 후속 확인

부록 · 정규화·형태소 재학습 비교

출처·라벨 상한 표본 (학습 11,559 / 검증 2,205 / 평가 2,211) · 특징 60,000개 · Kiwi 0.24.0

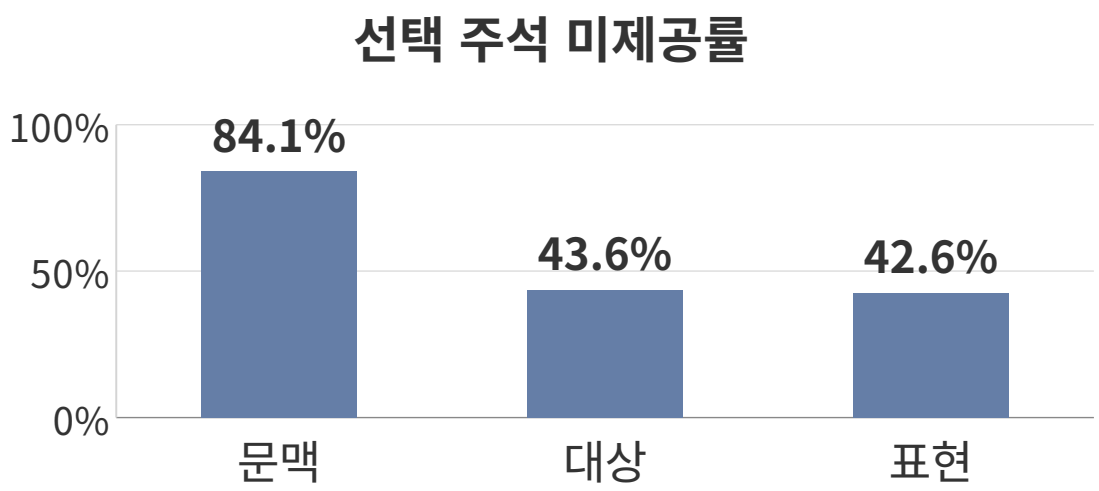
재학습 모델	검증 F1	평가 F1	유해 재현율	일반 오탐률
원문 문자 (기준)	0.7349	0.7360	76.31%	29.16%
+ 정규화 문자	0.7392	0.7273	70.12%	24.46%
+ 형태소	0.7473	0.7462	73.43%	24.08%
+ 정규화 문자 + 형태소	0.7416	0.7345	74.91%	28.03%

형태소: F1 +0.0102지만 재현율 하락·문맥 오류 그대로 → 형태소 제외 결정

소규모 표본·단일 seed · 현재 운영 모델의 F1과 직접 비교하지 않음

부록 · 선택 주석 미제공률과 필수화 비교

EDA · 정제 후 311,661행 기준 · Hadoop과 무관한 Python 분석



보조 검증: 선택 주석 필수화

7,149행

전체의 2.3%만 남음

가상 정책 비교 · 실제 삭제 아님

모두 필수로 하면 304,512행(97.7%) 제외 → 미채택, 주석 보존

빈 주석은 원천 미제공과 비해당이 섞임 · 결측 오류로 보지 않음 · 실제 삭제 없음

부록 · 시연 화면 추가 사례

공개 웹 녹화 장면 · 결과 패널만 잘라 표시

욕설 · 95.57 유해 / 욕설 58.43



후보 삭제 · 98.78 → 87.02 (−11.76)



특징 없음 · 판단 보류

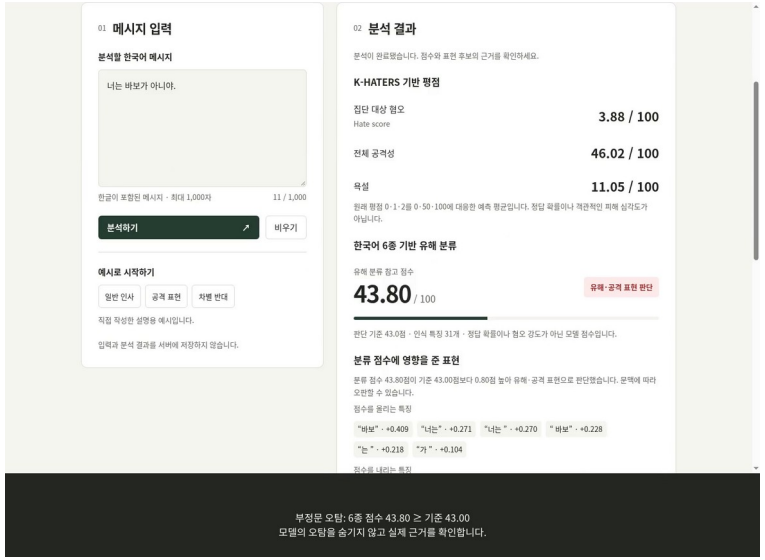


후보 삭제 비교와 보류는 6종 분류기의 설명 · K-HATERS 평점의 근거가 아님

표현 후보는 사람이 확정한 유해 구간이 아님 · 구간 삭제 시 문장 의미도 달라짐

부록 · 시연 영상 (46초)

공개 웹 실제 입력 5개 녹화 · 자막 해설 포함 · 무음



본문 5분에 포함하지 않음 · 질의응답 또는 시간 여유가 있을 때 재생

공개 주소 장애 시 이 영상으로 대체 · 클릭하면 재생