혐오체인 :
한국어 유해표현 분석 웹 페이지

한국어 유해표현 분류 모델 개발 및 웹 기반 검증

2101018 조규상
2001584 서재철
2201331 윤건호

주제와 실행 범위

초기 제안: **임베딩 Top-K 유사 사례 검색** → 현재: **한국어 6종 통합·분류·웹 검증**

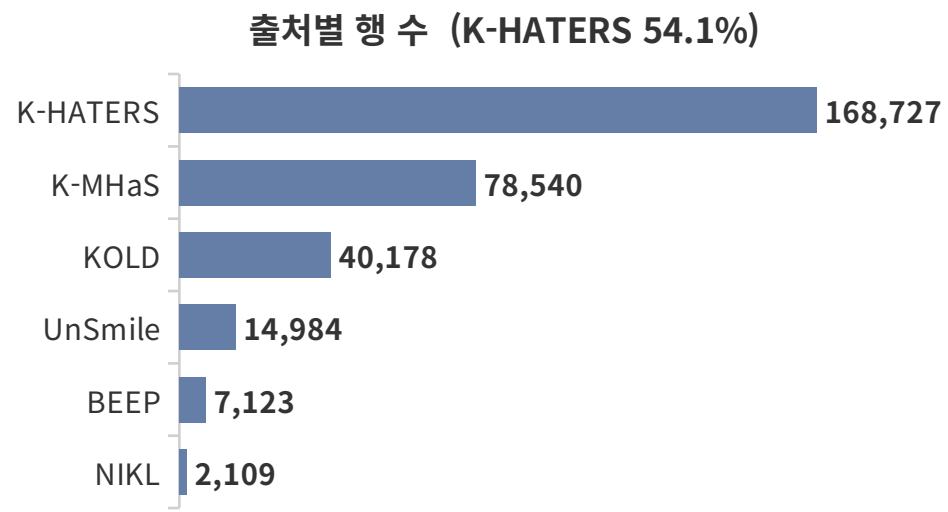
범위 결정 이유	확인한 차이
언어 구조	한국어와 영어의 **어순과 정보 위치** 차이
데이터 구성	언어별 **데이터 양의 불균형**
라벨 체계	한국어 **세부 유형**과 영어 **toxic 라벨**의 차이

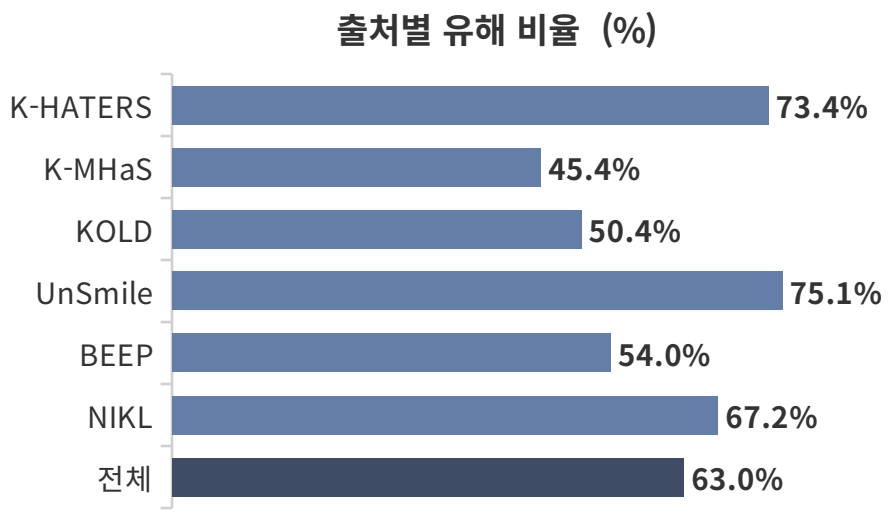
NIKL · UnSmile · KOLD · K-MHaS · K-HATERS · BEEP 라벨

중간 범위: **통합 데이터·분류기·웹 연결** / 임베딩 검색: **후속 작업**

데이터셋 EDA

한국어 6종 · 정제 후 **311,661행** · 필수값(문장·라벨·출처) **결측 0** · 문장 길이 **중앙값 35자**





K-HATERS가 54.1% · 전체 유해 63.0% · 출처·라벨 모두 불균형

선택 주석 미제공률: 문맥 **84.1%** · 대상 43.6% · 표현 42.6% (**삭제하지 않고 보존**)

전처리 파이프라인과 빅데이터 적용 위치

행 수는 각 단계 적용 후 · **원문은 보존**하고 공백 정리는 **중복 판별용**

1 수집·파싱 — Python
6종 원천을 **공통 스키마**로 변환
316,574행

→

2 필수값 검사 — Python
빈 문장·라벨 누락 제외
316,571행 (−3)

→

3 정제 — Python + Spark
공백 정규화·충돌 제외·중복 병합
311,661행 (−4,910)

4 그룹 분할 — Python
연결 그룹 단위 80/10/10
249,732 / 30,580 / 31,349

→

5 저장·집계 — Hadoop
HDFS 저장 + MapReduce 집계
27개 키·해시 일치

→

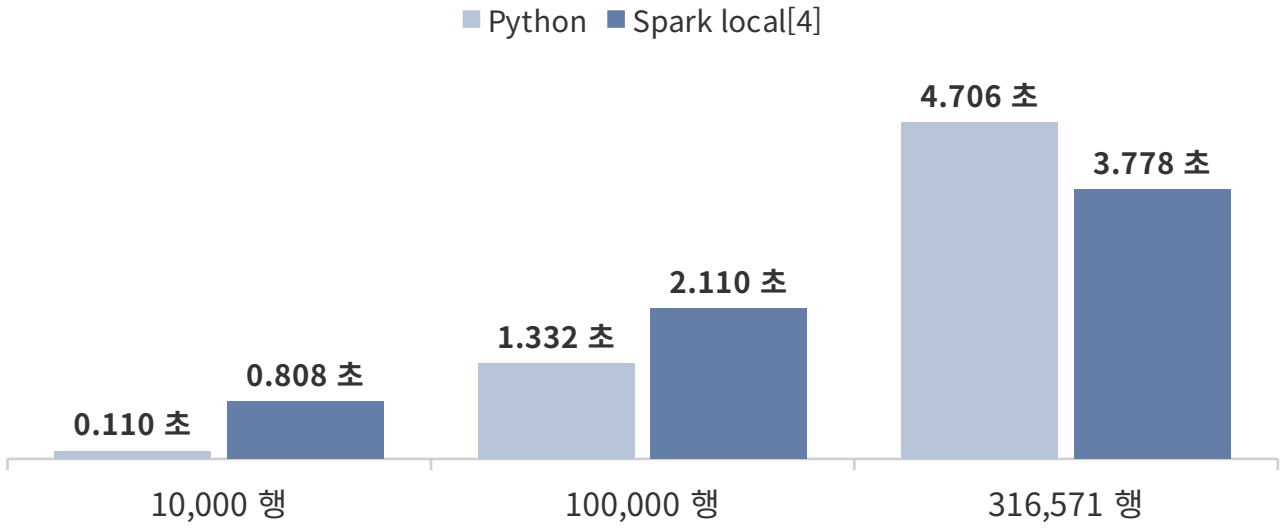
6 학습 — scikit-learn
문자 TF-IDF + LogisticRegression
모델 2종 (7장)

빅데이터 처리: 3단계 정제 = Spark, 5단계 저장·집계 = Hadoop

두 구간 모두 Python 결과와 **해시·집계 일치**로 검증 · **단일 서버 실행**, 다중 서버 확장은 후속

같은 전처리 구간의 Python·Spark 비교

공백 정규화·충돌 제외·중복 처리 · **단일 서버 Python과 Spark local**, 각 **3회 중앙값**



출력 키 해시

3/3 일치

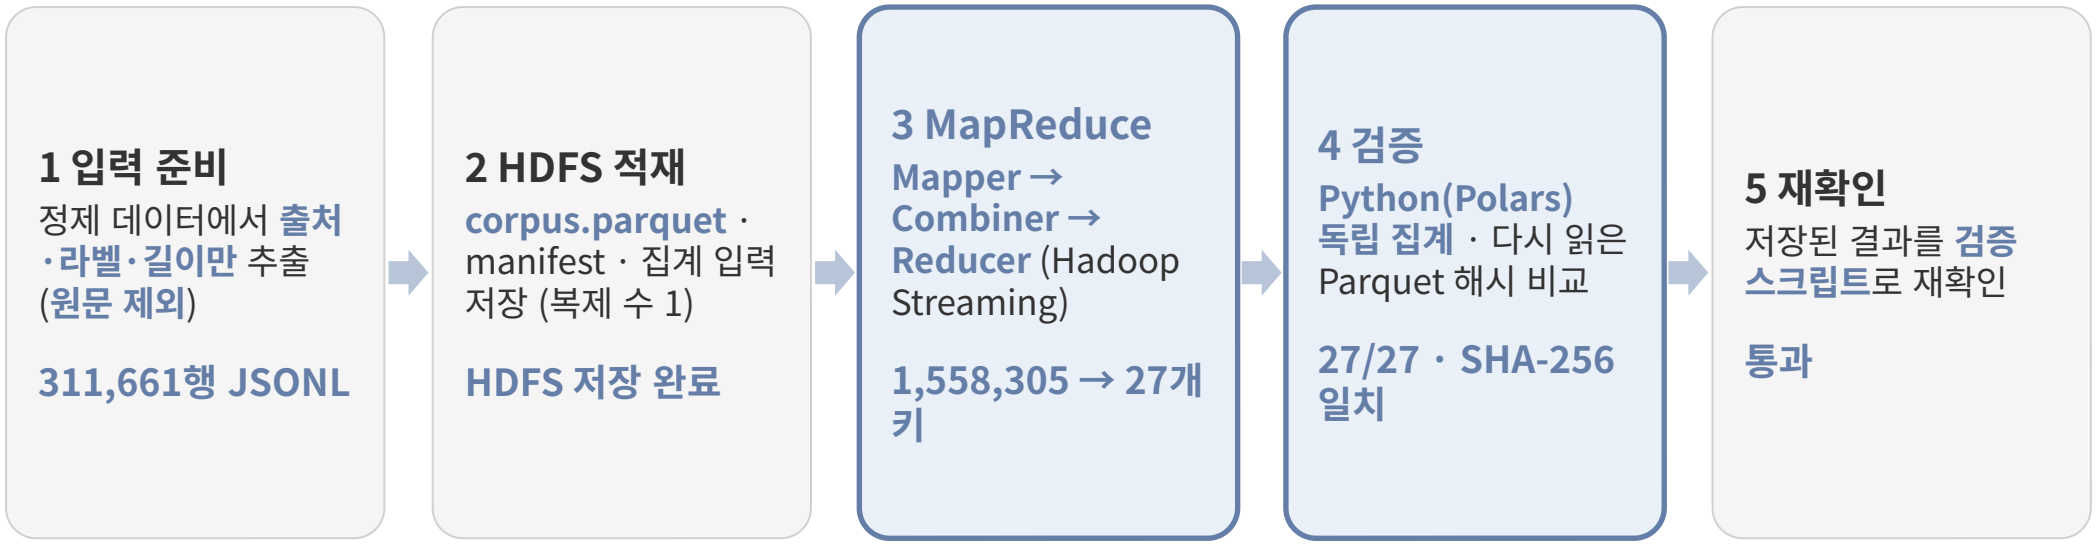
세 규모 모두 Python과 같은 결과
31.7만 행에서만 Spark가 더 짧음

Parquet 읽기·결과 수집 포함 / Spark 시작 3.302초 별도

전체 수집·분할이나 **다중 서버 확장성**의 비교가 아님

Hadoop 기반 저장·집계 검증

Hadoop 3.4.2 · **단일 서버 HDFS + MapReduce** LocalJobRunner · **YARN 미사용**



정제 결과를 별도 저장·집계 경로로 교차검증 → 27개 키·Parquet 해시 일치

단일 서버 실증 · 전체 전처리 재구현이나 다중 서버 성능 실험이 아님

모델 구성과 입력·출력

전처리한 6종 데이터 → **모델 A 학습** · 웹은 한 입력에 **두 모델 결과를 함께** 표시

구분	모델 A · 6종 이진 분류	모델 B · K-HATERS Ratings
입력	한국어 문장 str · **1–1000자** · **한글 포함**	같은 입력 (웹에서 동시 추론)
학습 데이터	6종 통합 train **249,732행**	원본 Ratings train **172,097행**
정답	**정상 / 유해** (출처 라벨을 이진 변환)	Hate·공격성·욕설 각 **0·1·2 등급**
특징	문자 2–5gram TF-IDF **200,000개**	문자 2–5gram TF-IDF **100,000개**
분류기	**LogisticRegression 1개** (balanced)	**LogisticRegression 3개 + 온도 보정**
출력	판정 **정상·유해·보류** + 점수 0–100	Hate·공격성·욕설 점수 0–100
판정·근거	**기준 43 이상 유해** · 기여 특징·후보 구간	**50 × (P(1) + 2·P(2))** · **판정 기준 없음**

보류: 학습한 문자 특징이 하나도 없으면 점수를 숨기고 판단 보류

모델 B는 7번째 출처가 아닌 **별도 데이터·별도 모델** · 점수는 **정답 확률·피해 심각도가 아님**

기존 이진 test 결과

기존 내부 test **31,349건** · 문자 2–5gram TF-IDF + LogisticRegression

Macro-F1

0.7784

정상·유해 두 클래스 **F1의 평균**

유해 재현율

83.52%

실제 유해 중 **유해로 찾은 비율**

정상 오탐률

27.82%

실제 정상 중 **유해로 판정한 비율**

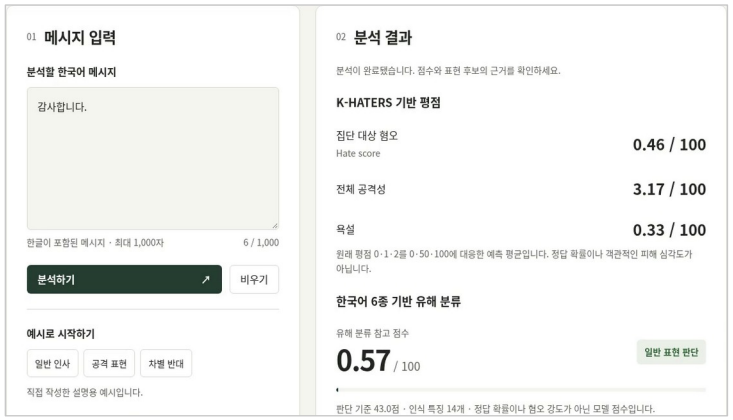
유해 문장을 찾는 성능과 정상 문장의 오탐을 함께 확인

Macro-F1은 **정확도가 아님** · 서비스 성능 보장이나 **독립 외부 평가가 아님**

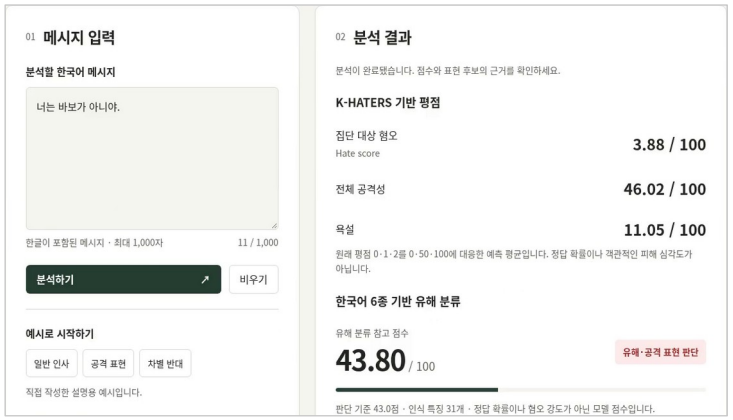
웹 실행과 부정문 오류

저장 모델을 **API로 호출**해 **결과와 특징** 표시

일반 문장 · 0.57 → 정상



부정문 · 43.80 ≥ 43 → 유해 (오탐)



QR로 직접 접속

qrfy.io/KeSupHr2bB

웹 구성: 상단 Ratings / 하단 이진 특징·삭제 전후 반응

시연 주소: playback-sight-profiles-defeat.trycloudflare.com

후속 실험 계획

현재 모델(문자 TF-IDF + LR)을 **기준선으로 고정** · 후보 선택은 **validation**, **test는 최종 1회** 보고

실험	목적	비교	평가 지표
E1 오류 유형 평가셋	**부정·인용·동음이의어 오탐** 측정	유형별 기준 작성 후 구축	**유형별 오탐률**
E2 짧은 입력 보류	**특징 1–2개**로 판정하는 문제 완화	인식 특징 수 기준값	**정상 오탐률·보류율**
E3 문맥 모델	**부정·문맥** 반영 여부 확인	사전학습 모델 vs 기준선	**Macro-F1·유형별 오탐**
E4 출처×길이 분석	출처별 **라벨 정의 차이** 확인	출처·길이 구간별 오류	**재현율·오탐률**

예: '시래기' 74.33 유해 — 학습 데이터 9건 모두 '쓰레기' 변형 욕설

E3 모델 종류·E2 기준값은 실험 전에 확정 · 계획이며 개선 결과를 **보장하지 않음**

소논문 방향과 작성 일정

주제(안): **다출처 한국어 유해표현 통합 데이터**와 문자 기반 분류기의 **오류 분석**

11/5–11/11	11/12–11/18	11/19–11/25	11/26–11/30	12월 초
관련 연구 정리 · 오류 유형 평가셋 구축 **(E1)**	보류 규칙·문맥 모델 비교 실험 **(E2·E3)**	출처×길이 분석 **(E4)** · 소논문 초안 작성	팀 검토·수정 · 최종 발표 자료 준비	최종 발표
→ 관련 연구 요약 · 평가셋	**→ 실험 결과표**	**→ 소논문 초안**	**→ 소논문 최종본 · 발표 자료**	**→ 시연 · 발표**

연구 질문: 문자 기반 분류기는 어떤 출처·문장 유형에서 틀리는가

11월 말까지 소논문 마무리 → **12월 초 최종 발표** · 최종 제목·범위는 팀 검토 후 확정

프로젝트 R&R과 예상 산출물

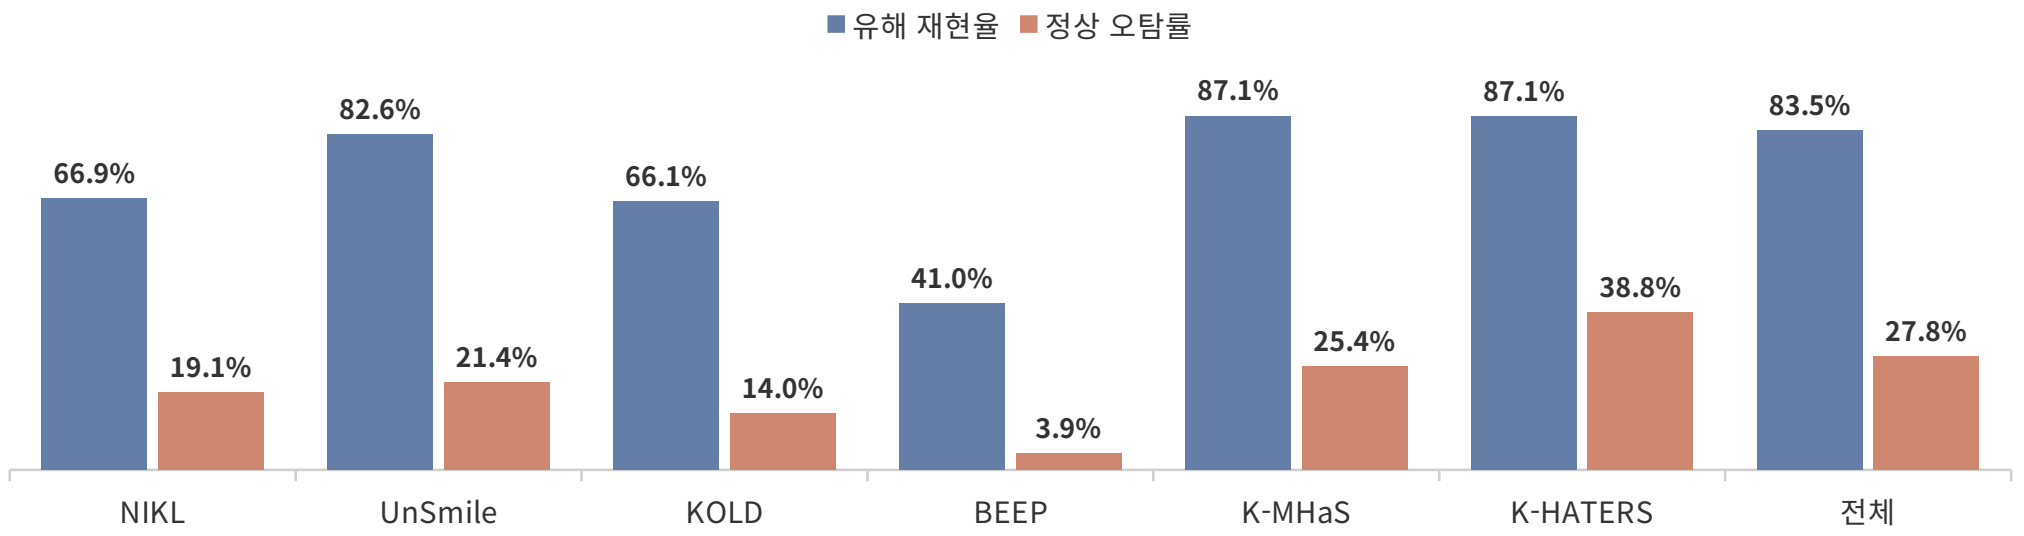
3인 역할 분담 · 결과 해석·전체 검토·리허설은 **공동**

이름	역할	주요 담당	예상 산출물
조규상	**모델·실험**	전처리 **공동** 주도·**모델 학습·비교·고정**	학습 모델·성능표·재현 정보
서재철	**데이터·자료**	전처리·라벨 점검·**오류 유형 분류**·PPT	오류 사례표·EDA·발표 자료
윤건호	**웹·서비스**	**웹 통합·시연 흐름**·점수 설명·연결 검증	웹 시연·백업 영상
공통	—	**결과 해석 검토·리허설·소논문 집필**	소논문·최종 발표

예상 산출물: 정제 데이터 · 모델 2종 · 웹 시연 · 소논문 · 최종 발표

부록 · 이진 모델의 출처별 test 성능

선택 모델(문자 2–5gram, 특징 200,000, 기준 0.43) · 기존 내부 test

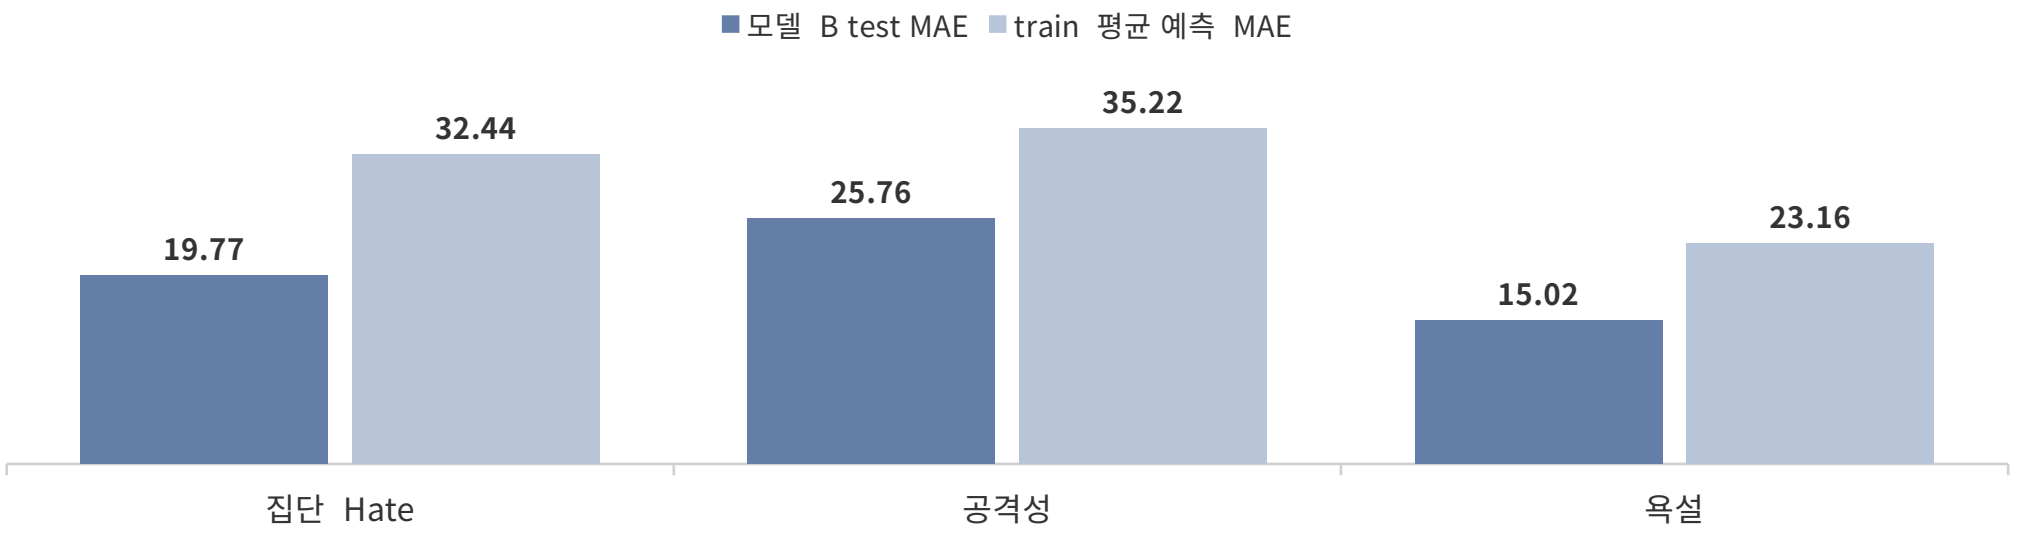


BEEP은 재현율이 낮고 K-HATERS는 오탐률이 높음 · A4 진단과 같은 방향

이미 확인한 test의 후속 집계 · 출처마다 라벨 정의가 달라 출처 간 우열 비교가 아님

부록 · K-HATERS Ratings 3종 성능

제한 정규화 v2 · 공식 validation/test 각 9,997건 · 점수 = 50 × (P(1) + 2·P(2))



세 점수 모두 train 평균 예측보다 MAE가 낮음 (Hate 32.44 → 19.77)

test는 이미 확인한 후속 비교 · 점수는 정답 확률이나 피해 심각도가 아님

부록 · 개선 후보와 선택

모델별 validation에서 선택 기준을 함께 비교

실험	주요 결과	선택
Ratings 제한 정규화	Hate MAE 19.9905 → 19.8762	채택
Ratings 불균형 보정	등급 0 오탐 5.40% → 21.78%	미채택
이진 문자 2–8gram	Macro-F1 0.784121 → 0.783041	기존 유지

한 지표의 상승보다 오차·오탐·재현율 조건을 함께 확인

이미 본 test의 후속 비교에서 욕설 MAE는 악화 · 독립 일반화 검증 아님

부록 · 출처·길이별 오류 진단

기존 validation의 고정 모델 재진단



validation 30,580건 중 API 허용·특징 인식 30,509건 기준

재학습·임계값 변경 없음 · 출처·길이 차이의 원인은 후속 확인

부록 · 정규화·형태소 재학습 비교

출처·라벨 상한 표본 (학습 11,559 / 검증 2,205 / 평가 2,211) · 특징 60,000개 · Kiwi 0.24.0

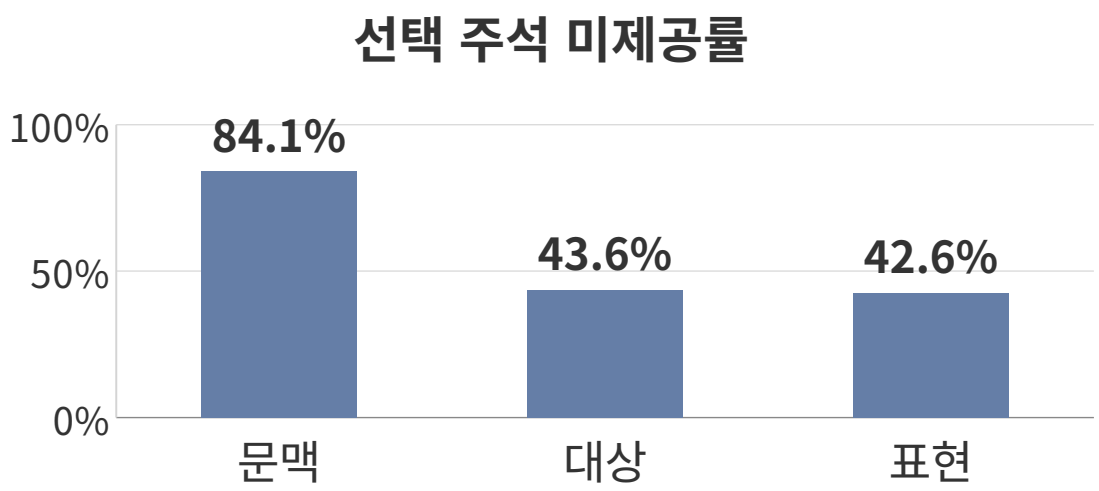
재학습 모델	검증 F1	평가 F1	유해 재현율	일반 오탐률
원문 문자 (기준)	0.7349	0.7360	76.31%	29.16%
+ 정규화 문자	0.7392	0.7273	70.12%	24.46%
+ 형태소	0.7473	0.7462	73.43%	24.08%
+ 정규화 문자 + 형태소	0.7416	0.7345	74.91%	28.03%

형태소: F1 +0.0102지만 재현율 하락·문맥 오류 그대로 → 형태소 제외 결정

소규모 표본·단일 seed · 현재 운영 모델의 F1과 직접 비교하지 않음

부록 · 선택 주석 미제공률과 필수화 비교

EDA · 정제 후 311,661행 기준 · Hadoop과 무관한 Python 분석



보조 검증: 선택 주석 필수화

7,149행

전체의 2.3%만 남음

가상 정책 비교 · 실제 삭제 아님

모두 필수로 하면 304,512행(97.7%) 제외 → 미채택, 주석 보존

빈 주석은 원천 미제공과 비해당이 섞임 · 결측 오류로 보지 않음 · 실제 삭제 없음

부록 · 시연 화면 추가 사례

공개 웹 녹화 장면 · 결과 패널만 잘라 표시

욕설 · 95.57 유해 / 욕설 58.43



후보 삭제 · 98.78 → 87.02 (−11.76)



특징 없음 · 판단 보류

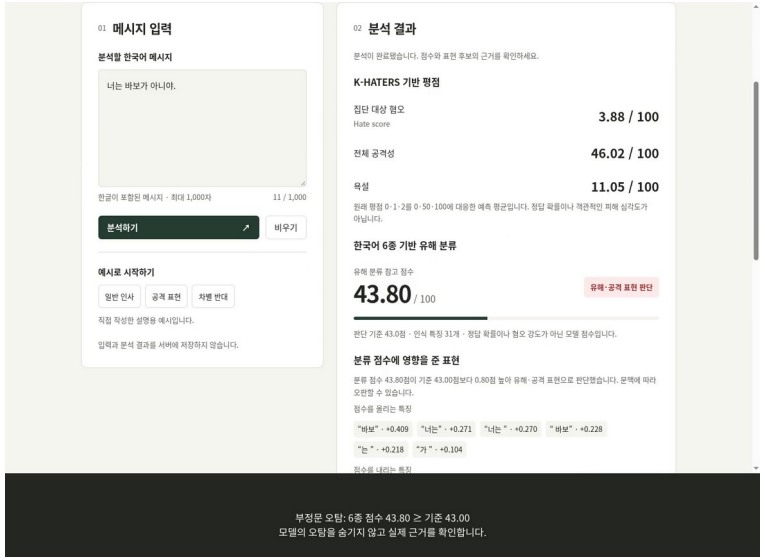


후보 삭제 비교와 보류는 6종 분류기의 설명 · K-HATERS 평점의 근거가 아님

표현 후보는 사람이 확정한 유해 구간이 아님 · 구간 삭제 시 문장 의미도 달라짐

부록 · 시연 영상 (46초)

공개 웹 실제 입력 5개 녹화 · 자막 해설 포함 · 무음



본문 5분에 포함하지 않음 · 질의응답 또는 시간 여유가 있을 때 재생

공개 주소 장애 시 이 영상으로 대체 · 클릭하면 재생